

Jelentés: A DeepLabV3+ architektúra és a MobileNet gerinchálózat integrációjának átfogó elemzése a vastagbélpolipok valós idejű szegmentálásában

1. Vezetői Összefoglaló és Bevezetés

A vastagbélrák (Colorectal Cancer - CRC) világszerte a rákkal összefüggő halálozások egyik vezető oka, amelynek megelőzése és korai felismerése döntő fontosságú a túlélési arányok javításában. A betegség patogenezise jellemzően a vastagbél nyálkahártyáján kialakuló polipokból, jóindulatú daganatokból indul ki, amelyek idővel rosszindulatúvá válhatnak. A gasztroenterológiában az arany standard szűrési módszer a kolonoszkópia, amely lehetővé teszi az orvosok számára a vastagbél belső felületének vizuális ellenőrzését és a gyanús képletek azonnali eltávolítását. A beavatkozás hatékonysága azonban erősen függ az endoszkópos orvos tapasztalatától és éberségétől; a fáradtság, a figyelem lankadása vagy a polipok nehéz észlelhetősége (például lapos vagy a környezetbe olvadó elváltozások esetén) jelentős hibaarányhoz vezethet. A statisztikák szerint a polipok felismerésének aránya (Adenoma Detection Rate - ADR) és a rák kialakulásának kockázata között fordított arányosság áll fenn, ami sürgető igényt teremtett a Számítógéppel Támogatott Diagnosztikai (Computer-Aided Diagnosis - CAD) rendszerek iránt.¹

Az utóbbi évtizedben a mélytanulás (Deep Learning) és a konvolúciós neurális hálózatok (Convolutional Neural Networks - CNN) forradalmasították az orvosi képfeldolgozást. Ezen belül a szemantikus szegmentálás – amely minden egyes képpontot osztályoz, elválasztva a polipot a háttértől – kritikus szerepet játszik, mivel pontosabb információt nyújt a lézió méretéről és alakjáról, mint az egyszerű detektálás (bounding box). A klinikai alkalmazás azonban szigorú követelményeket támaszt: a modelleknek nemcsak nagy pontosságot (magas Dice-együtthatót és IoU értéket) kell elérniük, hanem valós időben, alacsony késleltetéssel kell működniük a beavatkozás során használt hardvereken, amelyek számítási kapacitása gyakran korlátozott.¹

Jelen jelentés kimerítő részletességgel elemzi a **DeepLabV3+** architektúra alkalmazását **MobileNetV2** (és a kapcsolódó könnyűsúlyú változatok) gerinchálózattal (backbone) kombinálva a polipok szegmentálására. Ez a hibrid megközelítés a DeepLab család fejlett kontextus-aggregációs képességeit (Atrous Spatial Pyramid Pooling - ASPP) ötvözi a MobileNet hatékony, mélységi szeparálható konvolúciókon alapuló struktúrájával. A jelentés

célja, hogy feltárja ezen architektúra elméleti alapjait, a specifikus orvosi képfeldolgozási kihívásokra (pl. tükröződés, lencsetorzítás, méretbeli variabilitás) adott válaszait, valamint számszerűsítse a teljesítménybeli kompromisszumokat a hagyományos, nehézsúlyú modellekkel (pl. ResNet50, Xception) szemben.

A dokumentum a rendelkezésre álló legfrissebb kutatási eredmények, benchmark adatok (CVC-ClinicDB, Kvasir-SEG) és technikai leírások szintetizálásával készült, különös tekintettel a valós idejű működés (FPS), a paraméterszám és a számítási műveletek (FLOPs) optimalizálására.⁴

2. A Szemantikus Szegmentálás Evolúciója az Orvosi Képpalkotásban

A polipok automatikus szegmentálásának megértéséhez elengedhetetlen a mögöttes technológia fejlődésének áttekintése. A korai módszerek kézzel tervezett jellemzőkön (szín, textúra, élek) alapultak, amelyek érzékenyek voltak a megvilágítás változásaira és a polipok morfológiai sokféleségére. A CNN-ek megjelenése, különösen a Fully Convolutional Networks (FCN) bevezetése, paradigmaváltást hozott, lehetővé téve a jellemzők automatikus, hierarchikus tanulását.

2.1 A Hagományos Kódoló-Dekódoló Modellek Korlátai

Az orvosi szegmentálásban sokáig az **U-Net** architektúra dominált. Ez a szimmetrikus kódoló-dekódoló struktúra "skip connection"-öket (ugró kapcsolatokat) használ a magas szintű szemantikai információk és az alacsony szintű térbeli részletek fúziójára. Bár az U-Net kiválóan teljesít statikus orvosi képeken (pl. CT, MRI), a kolonoszkópia dinamikus környezetében és a polipok változatos méretében (scale variation) gyakran korlátokba ütközik. A polipok mérete a néhány millimétertől a több centiméterig terjedhet, és a kamera távolsága folyamatosan változik. A hagyományos konvolúciós rétegek fix receptív mezője (receptive field) nehezen kezeli ezt a léptékbeli variabilitást.⁷

2.2 A DeepLab Család Innovációi

A Google által fejlesztett DeepLab család éppen ezt a problémát, a többléptékű kontextus megragadását célozta meg. A fejlődés lépcsőfokai a következők voltak:

1. **DeepLabV1 és V2:** Bevezették az **atrous (dilatált) konvolúciót**. A hagyományos konvolúcióval ellentétben, amely szomszédos pixeleket dolgoz fel, az atrous konvolúció "lyukakat" (nullákat) illeszt a szűrő súlyai közé. Ez lehetővé teszi a receptív mező kiterjesztését anélkül, hogy növelné a paraméterek számát vagy csökkentené a felbontást (downsampling). A DeepLabV2 bevezette az **Atrous Spatial Pyramid Pooling (ASPP)** modult, amely párhuzamosan alkalmaz különböző rátájú atrous konvolúciókat, így a hálózat egyszerre "látja" a képet különböző nagyításokban.⁹

2. **DeepLabV3:** Tovább finomította az ASPP modult, beépítve a globális átlagolást (global average pooling) a kép szintű kontextus megragadására, és elhagyta a számításigényes feltételes véletlen mezőket (CRF), amelyeket korábban utófeldolgozásra használtak. A hangsúly a tisztán konvolúciós, end-to-end tanulásra helyeződött át.⁹
3. **DeepLabV3+:** Ez a verzió jelenti a jelenlegi csúcstechnológiát a családban. Felismerve, hogy a DeepLabV3 kiválóan ragadja meg a szemantikai jelentést ("mi van a képen"), de a durva felbontás miatt pontatlan az élek mentén ("hol van pontosan"), a V3+ egy **dekódoló modult** illesztett a rendszerhez. Ez a dekódoló a felskálázott (upsampled) kimenetet ötvözi a gerinchálózat korábbi rétegeiből származó, nagy felbontású, alacsony szintű jellemzőkkel, így képes visszaállítani a polipok éles határait, ami kritikus a pontos reszekcióhoz.⁹

3. A Hatékonyság Kulcsa: MobileNet Architektúrák

A DeepLabV3+ eredetileg nagyméretű gerinchálózatokkal (pl. Xception-65, ResNet-101) került bemutatásra, amelyek több tízmillió paraméterrel rendelkeznek és hatalmas számítási teljesítményt igényelnek. Ez alkalmatlanná teszi őket a valós idejű endoszkópos felhasználásra, ahol a processzorok (gyakran beágyazott rendszerek vagy orvosi munkaállomások) teljesítménye és hőtermelése korlátozott. A megoldást a gerinchálózat cseréje jelenti a **MobileNet** családra.¹

3.1 Mélységi Szeparálható Konvolúció (Depthwise Separable Convolution)

A MobileNetV1 alapvető innovációja a standard konvolúció felbontása két különálló, hatékonyabb műveletre. Tekintsünk egy standard konvolúciós réteget, amely

$D_F \times D_F \times M$ méretű bemenetet transzformál $D_G \times D_G \times N$ méretű kimenetű egy $D_K \times D_K$ méretű kernellel.

A számítási költség (Mult-Adds):

$$D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F$$

A mélységi szeparálható konvolúció ezt két lépésre bontja:

1. **Mélységi konvolúció (Depthwise Convolution):** Minden bemeneti csatornára (M) egyetlen $D_K \times D_K$ szűrőt alkalmaz. Nem hoz létre új jellemzőket a csatornák kombinálásával, csak térbeli szűrést végez.
2. **Pontoztató konvolúció (Pointwise Convolution):** Egy 1×1 méretű konvolúció, amely

lineárisan kombinálja a mélységi réteg kimeneteit, létrehozva az N új csatornát.¹⁴

A kombinált költség:

$$D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F$$

A számítási megtakarítás aránya:

$$\frac{D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F}{D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F} = \frac{1}{N} + \frac{1}{D_K^2}$$

Egy tipikus 3×3 kernel esetén ez a műveletigényt **8-9-szeresére csökkenti** minimális pontosságvesztés mellett.¹⁴ Ez a matematikai alap teszi lehetővé, hogy a DeepLabV3+ MobileNet gerinccel valós időben fusson.

3.2 MobileNetV2: Fordított Reziduális Blokkok (Inverted Residuals)

A polip szegmentálás szempontjából a **MobileNetV2** a legelterjedtebb választás. Ez a verzió továbbfejlesztette az architektúrát az **Inverted Residuals with Linear Bottlenecks** (Fordított Reziduális Blokkok Lineáris Szűkítéssel) bevezetésével.

A hagyományos ResNet blokk ("Wide-Narrow-Wide") először csökkenti a dimenziót (1x1), konvolvál, majd növeli. Ezzel szemben a MobileNetV2 ("Narrow-Wide-Narrow"):

1. **Kiterjesztés (Expansion):** Egy 1x1 konvolúcióval növeli a csatornák számát (általában 6-szorosára, $t = 6$), hogy a hálózat magasabb dimenzióban tanulhasson gazdagabb jellemzőket.
2. **Mélységi Konvolúció:** A kiterjesztett téren végzi a 3×3 szűrést.
3. **Vetítés (Projection/Bottleneck):** Egy 1x1 konvolúcióval visszacsökkenti a dimenziót.

A kritikus újítás a **lineáris aktiváció** használata a kimeneti bottleneck rétegben. A kutatások kimutatták, hogy a nem-lineáris aktivációk (mint a ReLU) alacsony dimenzióban információvesztést okoznak ("manifold collapse"). A lineáris kimenet megőrzi a polipok finom texturális információit, ami elengedhetetlen a szegmentáláshoz.¹⁶

4. Részletes Architektúrális Elemzés: DeepLabV3+ és MobileNetV2 Integrációja

A két technológia egyesítése egy olyan "Li-DeepLabV3+" (Lightweight DeepLab) modellt eredményez, amely optimalizálva van az orvosi képalkotás igényeire. Az alábbiakban

részletesen elemezzük a komponensek felépítését és interakcióját a polip szegmentálás kontextusában.

4.1 A Kódoló (Encoder) Konfigurációja

A standard DeepLabV3+ kódolója a MobileNetV2 hálózatra cserélődik. A bemeneti kép (általában 384×384 vagy 512×512 pixel felbontású kolonoszkópos képkocka) áthalad a MobileNetV2 rétegein. A legfontosabb módosítás a **kimeneti lépésköz (Output Stride - OS)** kezelése. A standard osztályozó hálózatok OS=32-re csökkentik a képet (azaz a bemenet 1/32-e a kimenet). A szegmentáláshoz ez túl durva. A DeepLabV3+ MobileNetV2 implementációjában az OS értéket jellemzően **16-ra** vagy **8-ra** állítják. Ezt úgy érik el, hogy a MobileNetV2 utolsó blokkjaiban (a 16. blokk után) eltávolítják a lépésközt (stride=1 a stride=2 helyett), és helyette **atrous konvolúciót** alkalmaznak a szűrőkön, hogy fenntartsák a receptív mezőt a felbontás csökkenése nélkül.¹²

A MobileNetV2 rétegek szerepe:

- Az első rétegek (stride 2, 4) felelősek az alacsony szintű jellemzők (élek, színek, nyálkahártya textúrája) kinyeréséért.
- A középső rétegek (stride 8, 16) a polipok komplexebb alakzatait és mintázatait (pl. pit pattern) ismerik fel.
- A legfelső réteg kimenete kerül az ASPP modulba.

4.2 Az ASPP Modul Finomhangolása

Az ASPP modul a kódoló "agya", amely a többléptékű kontextusért felelős. Egy tipikus MobileNetV2 alapú DeepLabV3+ ASPP modulja a következő ágakat tartalmazza:

1. Egy 1×1 konvolúció (központi jellemzők).
2. Három 3×3 atrous konvolúció különböző rátákkal (pl. 6, 12, 18).
3. Egy globális átlagoló (Global Average Pooling) ág, amely a teljes kép kontextusát tömöríti egyetlen vektorba, majd felnagyítja.

Probléma és Megoldás (HDC): A standard (6, 12, 18) ráták néha "sakktábla-effektust" (gridding artifact) okozhatnak, ahol a dilatáció miatt a pixelek közötti információ elvész, különösen kisebb polipok esetén. A szakirodalom¹ javasolja a **Hybrid Dilated Convolution (HDC)** alkalmazását, ahol a rátákat úgy választják meg, hogy ne legyen közös osztójuk (pl. 1, 2, 5), így biztosítva a receptív mező teljes lefedettségét és a vakfoltok kiküszöbölését. Ez kritikus a polipok szaggatott széleinek pontos követéséhez.

4.3 A Dekódoló (Decoder) Felépítése és Működése

A dekódoló feladata a kódoló által tömörített szemantikai információ (ahol a polip van) és a térbeli részletek (hol van a széle) egyesítése.

1. **Felskálázás:** Az ASPP kimenetét 4-szeresére nagyítják (bilineáris interpolációval).
2. **Alacsony Szintű Jellemzők Kinyerése:** A MobileNetV2 második vagy harmadik blokkjából (ahol a felbontás még nagy, OS=4) kinyerik a jellemzőtérképet. Ezek a térképek gazdagok él-információban.
3. **Csatornacsökkentés (1x1 Conv):** Mivel az alacsony szintű jellemzők csatornaszáma magas lehet, egy 1×1 konvolúcióval csökkentik a csatornák számát (pl. 48-ra vagy 24-re). Ez azért fontos, hogy a fúzió során ezek az "erős" jellemzők ne nyomják el a kódolóból érkező, fontosabb szemantikai információkat.¹²
4. **Konkatenáció és Finomítás:** A két ágat összefűzik, majd egy vagy két 3×3 konvolúciós rétegen küldik át. Ez a lépés "simítja" el a fúziós hibákat és élesíti a polip határait.
5. **Végső Predikció:** Egy újabb 4-szeres felskálázás állítja elő az eredeti képmérettel megegyező bináris maszkot.¹⁹

5. Teljesítményelemzés és Összehasonlító Vizsgálatok

A javasolt architektúra életképességét a benchmark adatok igazolják. Az elemzéshez a **CVC-ClinicDB** (612 kép), **Kvasir-SEG** (1000 kép) és **CVC-ColonDB** adatbázisok eredményeit használjuk fel.⁴

5.1 Pontosság (Accuracy Metrics)

A legfontosabb mérőszámok a **Dice-együttható (mDice)** és az **Unió és Metszet Aránya (mIoU)**.

1. Táblázat: Összehasonlító eredmények a CVC-ClinicDB és Kvasir-SEG adatkészleteken ¹

Modell Típus	Gerinchálózat (Backbone)	Adatkészlet	mDice (%)	mIoU (%)	Megjegyzés
Li-DeepLabV3+	MobileNetV2	CVC-ClinicDB	93.79 - 96.54	85.00 - 90.00	Figyelem mechanizmussal és optimalizált dekódolóval.
Li-DeepLab	MobileNetV	Kvasir-SEG	96.08	N/A	Kiváló

bV3+	2				általánosítási képesség heterogén adatokon.
Standard DeepLabV3+	MobileNetV2	CVC-Clinic DB	92.01	85.47	Alap implementáció.
Standard DeepLabV3+	ResNet50	CVC-Clinic DB	~93.00 - 94.10	~87.00	Magasabb számítási igényű referencia.
U-Net	Standard CNN	CVC-Clinic DB	~89.00 - 90.00	~82.00	Régebbi standard, gyengébb kontextus kezelés.
U-Net++	ResNet	Kvasir-SEG	91.00 - 92.00	~84.00	Továbbfejlesztett U-Net.

Elemzés: Az adatok azt mutatják, hogy a MobileNetV2 alapú DeepLabV3+ (különösen a Li-DeepLabV3+ variáns) képes megközelíteni, sőt, bizonyos esetekben (pl. fejlett figyelem modulokkal kiegészítve) felülmúlni a jóval nehezebb ResNet50 alapú modelleket. A standard U-Net-hez képest jelentős, 3-4%-os javulás tapasztalható a Dice-értékben, ami a polipok pontosabb körvonalazását jelzi.⁵

5.2 Számítási Hatékonyság (Efficiency Metrics)

A valós idejű alkalmazás szempontjából a paraméterszám és a FLOPs (lebegőpontos műveletek száma) a döntő.

2. Táblázat: Erőforrás-igény összehasonlítása ⁵

Modell Konfiguráció	Paraméterek (millió)	FLOPs (Giga)	Sebesség (FPS - GPU)	Sebesség (FPS - CPU)
---------------------	----------------------	--------------	----------------------	----------------------

DeepLabV3+ (Xception)	~54.7 M	> 80 G	~15-20	< 1
DeepLabV3+ (ResNet50)	~40-50 M	~60-70 G	~20-25	< 2
DeepLabV3+ (MobileNetV2)	2.1 - 5.8 M	1.6 - 5.0 G	> 40-50	~10-15
U-Net	~30 M	~60 G	~25	~2-3

Következtetések:

- **Paramétercsökkenés:** A MobileNetV2 használata közel **tízszeresére csökkenti** a modell méretét a ResNet/Xception változatokhoz képest. Ez lehetővé teszi a modell tárolását és futtatását az endoszkópos torony beágyazott rendszerein, internetkapcsolat nélkül.
- **Sebesség:** A 40-50 FPS (GPU-n, pl. GTX 1080 vagy újabb) bőven meghaladja a kolonoszkópia 25-30 FPS-es videófolyamát, így a szegmentálás folyamatosnak, akadózásmentesnek tűnik az orvos számára. Még CPU-n is megközelíti a valós idejű működést, ami költséghatékony implementációt tesz lehetővé.⁷
- **Energiahatékonyság:** Az alacsony FLOPs érték kevesebb hőtermelést jelent, ami kritikus az orvosi műszerek zárt, passzív hűtésű házaiban.

6. Speciális Kihívások és Megoldások a Polip Szegmentálásban

A laboratóriumi benchmarkok és a valós klinikai környezet között jelentős különbségek vannak. A DeepLabV3+ MobileNetV2 architektúrát számos módon kell adaptálni a speciális képi hibák kezelésére.

6.1 Tükröződések (Specular Reflections) és Fényviszonyok

A vastagbél nedves felülete és az endoszkóp erős fényforrása intenzív, fehér tükröződéseket okoz a képen. Ezek a "kiégett" pixelek megtéveszthetik a hálózatot, mivel éles kontrasztot alkotnak, hasonlóan a polipok széleihez, vagy elfedhetik a polip textúráját.²⁵

- **Megoldás:** A kutatások **térbeli figyelem (Spatial Attention)** modulok beépítését javasolják a DeepLab dekódolójába. Ezek a modulok megtanulják súlyozni a pixeleket fontosságuk szerint, így a hálózat "figyelmen kívül hagyja" a nagy intenzitású zajt, és a

mögöttes struktúrára koncentrál. Ezen kívül a betanítás során alkalmazott augmentáció (fényerő, kontraszt véletlenszerű változtatása) robusztussá teszi a modellt.¹

6.2 Lencsetorzítás (Lens Distortion)

Az endoszkópok széles látószögű (halszem) lencsét használnak, hogy minél nagyobb területet lásson az orvos. Ez a kép szélein jelentős hordótorzítást okoz, ami megváltoztatja a polipok alakját.²⁵

- **Adaptáció:** A DeepLabV3+ ASPP modulja természeténél fogva ellenállóbb a geometriai torzításokkal szemben, mivel a dilatált konvolúciók szélesebb kontextust fognak át, így a lokális torzítás kevésbé befolyásolja a globális felismerést. Azonban a legfejlettebb rendszerek előfeldolgozási lépésként szoftveres torzítás-korrektort alkalmaznak, vagy olyan adatbázisokon tanítják a hálózatot, amelyek tartalmazzak torzított mintákat is.⁴

6.3 Kis Polipok és Változó Méretek

A legnagyobb diagnosztikai kihívást a kisméretű (<5mm) és lapos (sessile) polipok jelentik. A standard DeepLabV3+ (6, 12, 18) rátái túl nagyok lehetnek ezekhez, és a polip "elveszhet" a lyukak között.

- **Li-DeepLabV3+ Módosítás:** Az úgynevezett **MSPP (Modified Simple Pyramid Pooling)** vagy optimalizált ASPP modulok kisebb, sűrűbb rátákat alkalmaznak (pl. 1, 2, 4, 8), és hangsúlyosabbá teszik az alacsony szintű jellemzők fúzióját a dekódolóban. Ez biztosítja, hogy a néhány pixelnyi információ is fennmaradjon a végső maszkig.¹

7. Fejlett Technológiák és Jövőbeli Irányok

A kutatás nem állt meg a MobileNetV2-nél. Újabb technikák integrálásával tovább növelhető a pontosság a sebesség feláldozása nélkül.

7.1 Unified Attention Fusion Module (UAFM)

A standard konkatenáció helyett a **UAFM** modulok intelligens fúziót végeznek. Ez a modul csatorna- és térbeli figyelmet alkalmaz a kódolóból érkező magas szintű és a gerincből érkező alacsony szintű jellemzőkre is az egyesítés előtt. Lényege, hogy dinamikusan dönti el, melyik jellemzőtérkép "fontosabb" az adott pixel osztályozásához. Például a polip határánál az alacsony szintű élinformációt erősíti fel, míg a polip közepén a szemantikai jelentést.¹

7.2 TransDeep: A Transformer és a CNN Hibridje

Bár a MobileNetV2 hatékony, a konvolúció lokális jellege korlátozza a globális összefüggések (long-range dependencies) megragadását. A legújabb trend, a **TransDeep**, a MobileNet gerinchálózatot ötvözi Transformer blokkokkal vagy önfigyelem (Self-Attention) mechanizmusokkal a bottleneck rétegekben. A Transformer képes a kép távoli pontjai közötti

kapcsolatokat is modellezni (pl. a bélredők mintázata vs. polip), ami javítja a szegmentálás konzisztenciáját, bár kissé növeli a számítási igényt.²⁹

7.3 MobileNetV3 és HardSwish

A MobileNetV3 megjelenése újabb optimalizációs lehetőséget kínál. A neurális architektúra-kereséssel (NAS) tervezett V3 verzió a **h-swish** (Hard Swish) aktivációs függvényt használja, amely számításilag olcsóbb és numerikusan stabilabb, mint a szigmoid alapú változatok. A kutatások szerint a MobileNetV3 Large gerinccel szerelt DeepLabV3+ hasonló pontosságot nyújt, mint a V2, de bizonyos CPU architektúrákon gyorsabb futást tesz lehetővé.³

8. Következtetés

A DeepLabV3+ architektúra és a MobileNetV2 gerinchálózat fúziója az orvosi mesterséges intelligencia egyik sikertörténete. A jelentésben bemutatott elemzés igazolja, hogy ez a kombináció sikeresen oldja fel az "exponenciális pontosság vs. lineáris sebesség" dilemmát.

A **mélyégi szeparálható konvolúciók** és az **invertált reziduális blokkok** matematikai hatékonysága lehetővé teszi, hogy a rendszer a másodperc törtrésze alatt dolgozzon fel nagy felbontású képeket, míg az **ASPP modul** és a **dekódoló** biztosítja azt a diagnosztikai precizitást, amely elengedhetetlen a polipok biztonságos azonosításához és eltávolításához. A benchmark eredmények (93-96% Dice) azt mutatják, hogy a megfelelő optimalizációkkal (pl. figyelem mechanizmusok, transzfer tanulás) a modell versenyképes a legnehezebb szerver-oldali hálózatokkal is.

A technológia érettsége mára lehetővé teszi a klinikai implementációt, ahol ezek a rendszerek "másodpilótaként" segítik az orvosokat, csökkentve az emberi hibák kockázatát és végső soron javítva a vastagbélrák megelőzésének hatékonyságát.

Melléklet: Technikai Fogalomtár

- **ASPP (Atrous Spatial Pyramid Pooling):** Olyan modul, amely párhuzamosan mintavételezi a bemenetet különböző rátájú atrous szűrőkkel, így több léptékben rögzíti a kép kontextusát.
- **Depthwise Separable Convolution:** A konvolúció faktorizációja egy térbeli szűrésre (depthwise) és egy csatorna-kombinációra (pointwise), amely drasztikusan csökkenti a műveletigényt.
- **Inverted Residual:** A MobileNetV2 építőeleme, amely a csatornák számát először növeli (kiterjesztés), konvolvál, majd csökkenti (projekció), ellentétben a klasszikus bottleneck struktúrával.
- **Dice Coefficient (F1 Score):** A szegmentálás pontosságának mérőszáma, a prediktált maszk és a valós maszk átfedését méri ($2 * \text{Metszet} / (\text{Predikció} + \text{Valóság})$).

- **IoU (Intersection over Union):** A Jaccard-index, a metszet és az unió hányadosa. Szigorúbb mérőszám, mint a Dice.
- **FLOPs (Floating Point Operations):** Lebegőpontos műveletek száma, a modell számítási komplexitásának és energiaigényének indikátora.

Works cited

1. Lightweight colon polyp segmentation algorithm based on improved DeepLabV3+ - PMC, accessed January 25, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC10751669/>
2. Modified DeeplabV3+ with multi-level context attention mechanism for colonoscopy polyp segmentation - PubMed, accessed January 25, 2026, <https://pubmed.ncbi.nlm.nih.gov/38320340/>
3. LM-DeeplabV3+: A Lightweight Image Segmentation Algorithm Based on Multi-Scale Feature Interaction - MDPI, accessed January 25, 2026, <https://www.mdpi.com/2076-3417/14/4/1558>
4. (PDF) A Lightweight DeepLabv3+ Model for Real-Time Polyp ..., accessed January 25, 2026, https://www.researchgate.net/publication/396461900_A_Lightweight_DeepLabv3_Model_for_Real-Time_Polyp_Segmentation_in_Colonoscopy_Images
5. Lightweight Deep Learning Model for Real-Time Colorectal Polyp Segmentation, accessed January 25, 2026, <https://snu.elsevierpure.com/en/publications/lightweight-deep-learning-model-for-real-time-colorectal-polyp-se/>
6. A Novel Road Segmentation Algorithm Based on Improved Deeplabv3+ - IEEE Xplore, accessed January 25, 2026, <https://ieeexplore.ieee.org/iel8/6287639/10380310/10562306.pdf>
7. lucasjinreal/pt_mobilenetv2_deeplabv3: Fast accurate ... - GitHub, accessed January 25, 2026, https://github.com/lucasjinreal/pt_mobilenetv2_deeplabv3
8. Polyp segmentation in colonoscopy images using DeepLabV3++ - ResearchGate, accessed January 25, 2026, https://www.researchgate.net/publication/382654426_Polyp_segmentation_in_colonoscopy_images_using_DeepLabV3
9. DeepLabV3+: A Powerful Architecture for Semantic Image Segmentation - Medium, accessed January 25, 2026, <https://medium.com/@deepvisionkararhaider/deeplabv3-a-powerful-architecture-for-semantic-image-segmentation-18c67b10d5be>
10. Insights of semantic segmentation using the DeepLab architecture for autonomous driving, accessed January 25, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12166448/>
11. A Guide to Using DeepLabV3 for Semantic Segmentation | Datature Blog, accessed January 25, 2026, <https://datature.io/blog/a-guide-to-using-deeplabv3-for-semantic-segmentation>
12. DeepLabv3 & DeepLabv3+ The Ultimate PyTorch Guide - Learn OpenCV, accessed January 25, 2026, <https://learnopencv.com/deeplabv3-ultimate-guide/>

13. DeepLabV3 Guide: Key to Image Segmentation - Ikomia, accessed January 25, 2026, <https://www.ikomia.ai/blog/understanding-deeplabv3-image-segmentation>
14. MobileNetV2: Inverted Residuals and Linear Bottlenecks - CVF Open Access, accessed January 25, 2026, https://openaccess.thecvf.com/content_cvpr_2018/papers/Sandler_MobileNetV2_Inverted_Residuals_CVPR_2018_paper.pdf
15. A Summary of the “MobileNetV2: Inverted Residuals and Linear Bottlenecks” Paper | by Zaynab Awofeso | CodeX | Medium, accessed January 25, 2026, <https://medium.com/codex/a-summary-of-the-mobilenetv2-inverted-residuals-and-linear-bottlenecks-paper-e19b187cb78a>
16. MobileNetV2: Inverted Residuals and Linear Bottlenecks (MobileNets v2), accessed January 25, 2026, https://patrick-lgc.github.io/Learning-Deep-Learning/paper_notes/mobilenets_v2.html
17. [1801.04381] MobileNetV2: Inverted Residuals and Linear Bottlenecks - arXiv, accessed January 25, 2026, <https://arxiv.org/abs/1801.04381>
18. MobileNetV2 Paper Walkthrough: The Smarter Tiny Giant | Towards Data Science, accessed January 25, 2026, <https://towardsdatascience.com/mobilenetv2-paper-walkthrough-the-smarter-tiny-giant/>
19. DeepLabV3+ Deep Dive. Understanding the building blocks of a... | by Ashwathsreeram | Medium, accessed January 25, 2026, <https://medium.com/@ashwathsreeram/deeplabv3-deep-dive-bd483d89677e>
20. Lightweight colon polyp segmentation algorithm based on improved DeepLabV3+ - Journal of Cancer, accessed January 25, 2026, <https://www.jcancer.org/v15p0041.pdf>
21. [2407.19327] Polyp segmentation in colonoscopy images using DeepLabV3++ - arXiv, accessed January 25, 2026, <https://arxiv.org/abs/2407.19327>
22. A Survey on Deep Learning for Polyp Segmentation: Techniques, Challenges and Future Trends - arXiv, accessed January 25, 2026, <https://arxiv.org/html/2311.18373v3>
23. DeepNeXt: a lightweight polyp segmentation algorithm based on multi-scale attention - PMC, accessed January 25, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11652027/>
24. Lightweight DeepLabv3+ for Semantic Food Segmentation - MDPI, accessed January 25, 2026, <https://www.mdpi.com/2304-8158/14/8/1306>
25. Two-stage deep-learning-based colonoscopy polyp detection incorporating fisheye and reflection correction | Request PDF - ResearchGate, accessed January 25, 2026, https://www.researchgate.net/publication/377435589_Two-stage_deep-learning-based_colonoscopy_polyp_detection_incorporating_fisheye_and_reflection_correction
26. Adjacent-differential network with shallow attention for polyp segmentation in colonoscopy images - NIH, accessed January 25, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12464208/>

27. Polyp segmentation in colonoscopy images using DeepLabV3+ - PubMed, accessed January 25, 2026, <https://pubmed.ncbi.nlm.nih.gov/40876416/>
28. Lightweight colon polyp segmentation algorithm based on improved DeepLabV3+, accessed January 25, 2026, <https://www.jcancer.org/v15p0041.htm>
29. TransDeep: Transformer-Integrated DeepLabV3+ for Image Semantic Segmentation - IEEE Xplore, accessed January 25, 2026, <https://ieeexplore.ieee.org/iel8/6287639/10820123/10820358.pdf>