

Átfogó Kutatási Jelentés: Korszerű Polipszegmentációs Architektúrák és Alternatívák a DeepLabV3+ Modellel Szemben Szakdolgozati Összehasonlító Elemzéshez

1. Vezetői Összefoglaló

A vastagbélrák (Colorectal Cancer - CRC) globálisan a második leghalálosabb daganatos megbetegedés, amelynek korai felismerése és megelőzése elsődlegesen a kolonoszkópos vizsgálatok során azonosított polipok eltávolításán alapul. A számítógéppel támogatott diagnosztika (Computer-Aided Diagnosis - CADx) területén az automatizált polipszegmentáció kulcsfontosságú technológiai kihívás, amely a polipok pontos pixel-szintű körülhatárolását célozza. Bár a DeepLabV3+ modell hosszú ideig ipari standardként szolgált az általános szemantikus szegmentációban, az orvosi képfeldolgozás, és specifikusan a polipszegmentáció területe az elmúlt években drasztikus fejlődésen ment keresztül. A jelenlegi kutatási eredmények egyértelműen azt mutatják, hogy a DeepLabV3+ architektúra, bár robusztus, már nem képviseli a csúcstechnológiát (State-of-the-Art, SOTA) sem pontosságban, sem számítási hatékonyságban, sem pedig a határok finom felbontásában.

Jelen jelentés célja, hogy részletes útmutatást nyújtson egy mesterszintű vagy doktori szakdolgozat kísérleti részének megtervezéséhez, amelyben a DeepLabV3+ modellt modernebb, specifikusan erre a feladatra optimalizált architektúrákkal vetik össze. A kutatás során azonosítottuk a legígéretesebb alternatívákat: a **PraNet** (Parallel Reverse Attention Network) a határok pontosságában ¹, a **HardNet-MSEG** a valós idejű feldolgozási sebességben ³, míg a **Polyp-PVT** (Pyramid Vision Transformer) és az **FCBFormer** a globális kontextus megértésében és a transzformer-alapú megközelítésekben múlja felül a hagyományos CNN-eket.¹ Ezen túlmenően, a 2025-ös és 2026-os év eleji kutatások olyan új irányokat jelöltek ki, mint az **UltraSeg** család, amely CPU-alapú környezetben teszi lehetővé a valós idejű futtatást, valamint a **Polyp-DiFoM**, amely a masszív Foundation modellek (mint a SAM vagy DINOv2) tudását desztillálja könnyűsúlyú hálózatokba.⁶

A jelentés részletesen tárgyalja ezen modellek architektúráis innovációit, a benchmark adathalmazokon (Kvasir-SEG, CVC-ClinicDB) elért teljesítményüket, és konkrét módszertani ajánlásokat fogalmaz meg a szakdolgozati összehasonlító elemzés végrehajtásához.

2. Bevezetés: A Polipszegmentáció Klinikai és Technológiai Kontextusa

2.1 A Klinikai Probléma: Miért Nem Elég a Detektálás?

A vastagbélrák prevenciójának arany standardja a kolonoszkópia, amelynek során az endoszkópos szakorvos vizuálisan átvizsgálja a vastagbelet, és eltávolítja a prekancerosus elváltozásokat, az úgynevezett polipokat. Azonban a vizsgálatok érzékenysége nagyban függ az orvos tapasztalatától és éberségétől; a szakirodalom szerint a polipok "miss rate"-je (fel nem ismerési aránya) 6% és 27% között mozog.⁸ A kis méretű, lapos (sessile) vagy a nyálkahártya redői mögött megbújó polipok különösen nagy kihívást jelentenek.

A mesterséges intelligencia (AI) alkalmazása ezen a területen két fő feladatra osztható: detektálás (bounding box rajzolása) és szegmentáció (pixel-szintű maszkolás). Egy szakdolgozat kontextusában fontos hangsúlyozni, hogy miért van szükség a komplexebb szegmentációra:

1. **Méretbecslés és Osztályozás:** A polip mérete közvetlenül korrelál a malignitás (rosszindulatúság) kockázatával. A pontos szegmentáció lehetővé teszi a polip átmérőjének automatikus mérését, ami a detektáló dobozok (bounding box) esetében pontatlan lenne.
2. **Sebészeti Tervezés:** A polip eltávolításakor (polypectomia) kritikus fontosságú a biztonsági zónák (safety margins) meghatározása, hogy a teljes kóros szövetet eltávolítsák, de a bélfal perforációját elkerüljék. A szegmentációs maszk pontosan kijelöli a vágási vonalat.
3. **CADx és Szövettani Predikció:** A modern rendszerek (pl. NICE vagy JNET osztályozás alapján) megpróbálják megjósolni a polip szövettani típusát (hiperplasztikus vs. adenóma). A szegmentáció izolálja a polip felszínét, eltávolítva a háttérzajt, így az osztályozó algoritmusok tisztább bemenetet kapnak.⁹

2.2 Az Orvosi Képfeldolgozás Specifikus Kihívásai

A polipszegmentáció nem pusztán egy "tárgyfelismerési" feladat, mint az autók vagy gyalogosok detektálása. A biológiai környezet egyedi nehézségeket támaszt, amelyek miatt az általános célú modellek – mint a DeepLabV3+ – gyakran kudarcot vallanak:

- **Morfológiai Variancia:** A polipok mérete a néhány milliméterestől a több centiméteresig terjedhet. Az alakjuk lehet kocsányos (gomba-szerű), lapos vagy besüppedt. Egyetlen modellnek kell kezelnie ezt az extrém skálázódást.⁸
- **Álcázás (Camouflage):** A lapos polipok színe és textúrája gyakran alig tér el a környező egészséges nyálkahártyától. A kontraszt hiánya miatt a hagyományos éldetektáló mechanizmusok csődöt mondanak.
- **Képmínőségi Artefaktumok:** A bélmozgás (perisztaltika) miatti elmosódás (motion blur), a fényforrás tükröződése a nedves felületeken (specular highlights), valamint a

székletmaradványok és folyadékok jelenléte mind olyan zajforrások, amelyeket a modellnek ignorálnia kell.¹¹

- **Bizonytalan Határok:** Ellentétben egy autóval, amelynek éles körvonalai vannak, a polipok szélei gyakran fokozatosan olvadnak bele a bélfalba ("fuzzy boundaries"). Ez a "bizonytalanság" (aleatoric uncertainty) megnehezíti a felügyelt tanulást, mivel még az orvosi szakértők által készített "ground truth" maszkok is szubjektívek lehetnek.

3. A Referencia Modell Elemzése: DeepLabV3+

Mielőtt rátérnénk a jobb alternatívákra, elengedhetetlen a jelenleg használt **DeepLabV3+** modell mélyreható elemzése. Egy szakdolgozatban ez szolgál majd a "baseline" (alapvonal) szerepében, amelyhez minden más eredményt viszonyítunk. A DeepLabV3+ leváltása nem csupán divat, hanem technológiai szükségszerűség az orvosi képalkotásban.

3.1 Architektúrális Felépítés és Működési Elv

A Google által fejlesztett DeepLabV3+ a szemantikus szegmentáció egyik mérföldköve, amely az enkóder-dekóder struktúrát ötvözi az úgynevezett **ASPP (Atrous Spatial Pyramid Pooling)** modullal.

- **Enkóder (Gerinchálózat):** Jellemzően egy ResNet (pl. ResNet-50, ResNet-101) vagy Xception hálózat, amely kivonja a képi jellemzőket. A DeepLabV3+ kulcsinnovációja az "atrous" (vagy dilatált) konvolúció alkalmazása. Ez a technika lyukakat hagy a konvolúciós kernel elemei között (dilatációs ráta), így növelve a receptív mezőt (a hálózat által "látott" területet) anélkül, hogy csökkentené a felbontást vagy növelné a paraméterszámot.¹³
- **ASPP Modul:** Ez a modul párhuzamosan futtat különböző dilatációs rátájú (pl. 6, 12, 18) konvolúciókat. Célja, hogy a hálózat egyszerre legyen képes érzékelni a kis részleteket (kis ráta) és a nagy objektumokat (nagy ráta). Ez elméletileg ideális lenne a változó méretű polipokhoz.
- **Dekóder:** A DeepLabV3+ bevezetett egy egyszerű dekódert, amely az enkóderből származó, alacsony szintű (low-level), de nagy felbontású jellemzőket fuzionálja a magas szintű szemantikus jellemzőkkel, hogy finomítsa a szegmentációs határokat.¹³

3.2 A DeepLabV3+ Korlátai a Polipszegmentációban

Miért keresünk jobb modellt? A kutatási anyagok alapján a DeepLabV3+ több kritikus ponton is alulteljesít a modern polip-specifikus modellekkel szemben:

1. **Határok Pontatlansága (Boundary Leakage):** Bár az atrous konvolúció növeli a receptív mezőt, hajlamos a "rácsosodásra" (gridding artifact), ami a finom részletek elvesztéséhez vezet. A polipok szélei gyakran egyenetlenek; a DeepLabV3+ hajlamos ezeket túlságosan kisimítani vagy "darabossá" tenni. A klinikai gyakorlatban a határ 1-2 mm-es tévesztése is jelentős lehet.¹⁵

2. **Globális Kontextus Hiánya:** A CNN-ek alapvetően lokális operátorok. A DeepLabV3+ még az ASPP-vel is csak korlátozottan képes összekötni a kép távoli pontjait. Ha egy polip textúrája nagyon hasonlít egy távoli bélredőre, a modell nem rendelkezik azzal a globális "látással" (mint a Transformer-ek), amely segítene megkülönböztetni a kettőt a kontextus alapján.¹⁶
3. **Számítási Nehézkedés:** A ResNet-101 gerinchálózattal szerelt DeepLabV3+ paraméterszáma magas (kb. 40-50 millió), és az inferencia sebessége (FPS) gyakran alacsony (17-28 FPS) átlagos hardveren. Ez akadályozza a valós idejű (real-time) videófeldolgozást az endoszkópos toronyban, ahol legalább 25-30 FPS, de inkább 60 FPS elvárás lenne a késleltetésmentes megjelenítéshez.⁴

4. CNN-alapú Versenytársak: PraNet és HarDNet-MSEG

A szakdolgozat összehasonlító részében az első logikus lépés a DeepLabV3+ összevetése olyan modern CNN-ekkel, amelyeket kifejezetten a polipok tulajdonságaira terveztek. Ezek a modellek nem igénylik a Transformer-technológia teljes hardverigényét, de okosabb architektúrával jobb eredményt érnek el.

4.1 PraNet: A Határok Mestere (Parallel Reverse Attention Network)

A **PraNet**¹ az egyik leggyakrabban idézett és benchmarkként használt modell a polipszegmentációban. Egy szakdolgozatban kiválóan használható annak demonstrálására, hogy a "figyelem" (attention) mechanizmusok hogyan javítják a pontosságot.

4.1.1 Innováció: A Fordított Figyelem (Reverse Attention)

Míg a DeepLabV3+ minden pixelt egyenlő súllyal kezel a konvolúció során, a PraNet egy biológiailag inspirált stratégiát alkalmaz. A hálózat először készít egy durva becslést a polip helyéről. Ezután a **Reverse Attention (RA)** modul megfordítja ezt a maszkot, azaz kitakarja a már biztosan megtalált polip-belsőket, és a figyelmet kizárólag a bizonytalan határookra és a háttérre irányítja.

- **Működési Mechanizmus:** Ez a folyamat iteratív. A hálózat "radírozással" finomítja a széleket, kényszerítve a modellt, hogy megtanulja a polip és a nyálkahártya közötti finom átmeneteket.
- **Párhuzamos Részleges Dekóder (PPD):** A teljes U-Net szerű dekódolás helyett a PraNet egy PPD modult használ, amely párhuzamosan aggregálja a magas szintű jellemzőket. Ez jelentősen felgyorsítja a működést a DeepLabV3+-hoz képest.

4.1.2 Teljesítmény és Összehasonlítás

A Kvasir-SEG adathalmazon a PraNet átlagos Dice-koefficiense (mDice) eléri a **0.898**-at, míg a DeepLabV3+ jellemzően **0.85-0.86** körül teljesít.¹⁸ Ez a ~4%-os javulás a gépi tanulásban

szignifikánsnak számít. A legfontosabb különbség azonban a Hausdorff Távolságban (HD95) mutatkozik meg, ahol a PraNet sokkal kisebb hibát vét a határokon.

4.2 HarDNet-MSEG: A Valós Idejű Hatékonyság Bajnoka

Ha a szakdolgozat fókuszában a "klinikai alkalmazhatóság" vagy a "valós idejű feldolgozás" áll, akkor a **HarDNet-MSEG**³ a tökéletes választás az összehasonlításához.

4.2.1 Innováció: Memória-Optimalizált Gerinchálózat

A GPU-k számítási sebességét gyakran nem a műveletek száma (FLOPs), hanem a memória-sávszélesség (DRAM traffic) korlátozza. A DenseNet-ek például nagyon pontosak, de rengeteg memóriamozgatást igényelnek. A HarDNet (Harmonic DenseNet) architektúra ezt oldja meg: ritkítja a kapcsolatokat a rétegek között egy harmonikus hullám mintázata alapján.

- **Eredmény:** A HarDNet-MSEG drasztikusan kevesebb memóriát használ, és gyorsabb inferenciát tesz lehetővé, miközben megőrzi a sűrű kapcsolatok (dense connections) előnyeit a jellemzők továbbításában.

4.2.2 Sebesség vs. Pontosság

A HarDNet-MSEG a benchmark teszteken **86.7 FPS** sebességet ért el egy RTX 2080 Ti kártyán, szemben a DeepLabV3+ **28 FPS** (ResNet50) vagy **17 FPS** (ResNet101) teljesítményével.⁴ Ez több mint háromszoros gyorsulás. Meglepő módon a pontossága is versenyképes: a Kvasir-SEG adathalmazon **0.904**-es mDice értéket ért el, ami még a PraNet-et is megközelíti vagy néha felülmúlja, bizonyítva, hogy a hatékonyság nem feltétlenül jár pontosságvesztéssel.¹⁹

4.3 DeepLabV3++: Az Evolúciós Lépés

Érdemes megemlíteni, hogy létezik a DeepLabV3+ továbbfejlesztett változata, a **DeepLabV3++**.²⁰ Ez a modell lecseréli a gerinchálózatot a modernebb EfficientNetV2S-re, és bevezet egy több-léptékű piramis pooling (MSPP) modult és egy párhuzamos figyelem aggregációs blokkot (PAAB).

- **Relevancia:** A kutatások szerint ez a modell **96.08%**-os Dice pontszámot ért el a Kvasir-SEG-en, ami kiemelkedő. Szakdolgozati szempontból érdekes lehet összehasonlítani a "sima" V3+-t ezzel a "tuningolt" változattal, demonstrálva a backbone és az attention modulok hatását.

5. A Transformer Forradalom: Polyp-PVT és Hibrid Modellek

A legmodernebb (SOTA) megközelítések ma már túllépnek a tiszta CNN-eken, és a Natural

Language Processing (NLP) területéről átvett Transformer architektúrákat alkalmazzák a vizuális feladatokra. Ez jelenti a legnagyobb ugrást a DeepLabV3+-hoz képest.

5.1 Polyp-PVT: Globális Kontextus Transzformerekkel

A **Polyp-PVT**¹ az első olyan modell, amely sikeresen alkalmazta a Pyramid Vision Transformer (PVT) struktúrát a polipszegmentációban, és vált de facto standarddá a modern összehasonlításokban.

5.1.1 Miért Jobb a Transzformer?

A DeepLabV3+ fő gyengéje a lokális receptív mező. A Polyp-PVT ezzel szemben a **Self-Attention** (ön-figyelem) mechanizmust használja.

- **Globális Összefüggések:** Matematikailag minden pixel "látja" minden másik pixel információját a figyelmi térképen keresztül. Ha a kép bal felső sarkában van egy polip-gyanús textúra, a modell össze tudja vetni a jobb alsó sarokban lévő egészséges szövettel. Ez a globális összehasonlítás segít kiszűrni a hamis pozitív találatokat (pl. széklet, redők), amelyeket a CNN-ek gyakran polipnak néznek.¹⁷
- **Cascaded Fusion Module (CFM):** Mivel a transzformerek hajlamosak elveszíteni a térbeli információt, a Polyp-PVT egy kaszkádolt fúziós modult használ, amely lépésről lépésre állítja vissza a felbontást, integrálva a szemantikus és a térbeli információkat.

5.1.2 Benchmark Eredmények

A Polyp-PVT a Kvasir-SEG adathalmazon **0.917**-es mDice értéket ért el, a CVC-ClinicDB-n pedig **0.937**-et.⁸ Ez a teljesítmény szignifikánsan meghaladja a DeepLabV3+ és sok esetben a PraNet eredményeit is, különösen a bonyolult, álcázott polipok esetében.

5.2 FCBFormer: A Teljes Felbontású Megközelítés

A transzformerek egyik hátránya, hogy a számítási igény csökkentése érdekében gyakran lemeretezik a képet, ami a határok elmosódásához vezet. Az **FCBFormer** (Fully Convolutional Branch Transformer)⁵ ezt a problémát hidalja át.

5.2.1 Hibrid Architektúra

Az FCBFormer két ágon dolgozza fel a képet:

1. **Transzformer Ág:** A PVT gerinchálózata segítségével kinyeri a robusztus globális szemantikai információt (hol van a polip?).
2. **Teljesen Konvolúciós Ág (FCB):** Az eredeti felbontáson dolgozik, hogy megőrizze a finom éleket és textúrákat (milyen a polip széle?).
3. **Fúzió:** A két ág információit egyesíti. Ezzel a módszerrel az FCBFormer kivételes általánosító képességet (generalization) mutat: ha az egyik adathalmazon tanítjuk és egy másikon teszteljük (cross-dataset validation), gyakran jobban teljesít, mint a

versenytársai.

6. Jövőbemutató Modellek és Irányok (2025-2026)

Ha a szakdolgozat célja a legfrissebb kutatási frontvonal bemutatása, akkor érdemes kitérni a 2024 vége és 2026 eleje között megjelent, feltörekvő modellekre is.

6.1 UltraSeg: CPU-alapú Valós Idejű Működés

A legtöbb SOTA modell (Polyp-PVT, PraNet) erős GPU-t igényel a valós idejű futtatáshoz. Azonban a kórházi endoszkópos tornyok többsége nem rendelkezik dedikált GPU-val. Az **UltraSeg-108K**⁶ egy 2026-os fejlesztés, amely extrém tömörítésre fókuszál.

- **Paraméterek:** Mindössze 108 000 paraméter (szemben a DeepLabV3+ ~40-50 milliójával).
- **Teljesítmény:** Képes **90 FPS** sebességgel futni egyetlen CPU magon. Bár a pontossága (mDice ~0.80-0.85) alacsonyabb lehet, mint a Polyp-PVT-é, a hozzáférhetősége forradalmi. Egy szakdolgozatban kiváló téma lehet a "DeepLabV3+ vs. UltraSeg" összehasonlítás a "Resource-Constrained Environments" (erőforrás-korlátos környezetek) szemszögéből.

6.2 Polyp-DiFoM: Tudásdesztilláció Foundation Modellekből

A mesterséges intelligencia jelenlegi legnagyobb trendje a Foundation modellek (pl. Meta SAM - Segment Anything Model, DINOv2) alkalmazása. Ezek a modellek "mindent látnak", de túl lassúak a klinikumba. A **Polyp-DiFoM**⁷ keretrendszer célja, hogy ezen óriásmodellek tudását "lepárolja" (distillation) kisebb, gyorsabb hálózatokba (pl. egy egyszerű U-Net-be).

- **Eredmény:** A desztillált modellek elérik a SOTA pontosságot anélkül, hogy a SAM lassúságával küzdenének.

7. Összehasonlító Benchmark Elemzés

Az alábbi táblázatok összegzik a legfontosabb metrikákat, amelyeket a szakdolgozatban fel lehet használni a DeepLabV3+ és a javasolt alternatívák összevetésére. Az adatok a szakirodalomban publikált, egységes tesztkörnyezetből származó értékek.⁴

7.1 Teljesítmény a Kvasir-SEG Adathalmazon

A **Kvasir-SEG**²⁷ az egyik legnehezebb, valós klinikai képeket tartalmazó adathalmaz, változó felbontással és sokféle polip típussal.

Modell	Architektúra Típus	Mean Dice (mDice)	Mean IoU (mIoU)	Sebesség (FPS, GPU)	Fő Előny
DeepLabV3+ (Baseline)	CNN (ResNet-50)	0.857 – 0.864	0.780 – 0.810	~28 FPS	Szabványos, széles körben ismert
PraNet	CNN + Reverse Attention	0.898	0.840	~60 FPS	Kiváló határ-detektálás
HarDNet-MSEG	CNN (Sparse)	0.904 – 0.912	0.848 – 0.857	~86.7 FPS	Extrém gyors, valós idejű
Polyp-PVT	Transformer (PVT)	0.917	0.864	~66 FPS	Globális kontextus, robusztusság
FCBFormer	Hibrid (ViT + CNN)	~0.930	~0.880	< 30 FPS	Legjobb általánosítás (Generalization)
DeepLabV3++	CNN (EfficientNetV2)	0.961	0.938	N/A	Modernizált klasszikus (Potenciális SOTA)

7.2 Teljesítmény a CVC-ClinicDB Adathalmazon

A **CVC-ClinicDB**²⁸ videókból kivágott képkockákat tartalmaz (SD felbontás), amelyek gyakran elmosódottabbak, de kevesebb varianciát mutatnak a Kvasir-SEG-nél.

Modell	Mean Dice (mDice)	Mean IoU (mIoU)	Megjegyzés

DeepLabV3+	0.880 – 0.890	0.830 – 0.860	Stabil, de nem kiemelkedő
PraNet	0.899	0.849	Jobb, mint a V3+, de kisebb a különbség mint a Kvasir-nál
HarDNet-MSEG	0.932	0.882	Jelentős ugrás a DeepLabV3+-hoz képest
Polyp-PVT	0.937	0.889	Kiváló teljesítmény videó frame-eken is

7.3 Erőforrás-igény Összehasonlítás

Egy szakdolgozatban nem elég csak a pontosságot vizsgálni. A modellek "súlya" és sebessége kritikus a klinikai bevezethetőség szempontjából.

Modell	Paraméterszám (Millió)	Inferancia Sebesség (GPU)	Alkalmasság Edge Eszközre
DeepLabV3+ (ResNet50)	~40.0 M	Közepes (~30 FPS)	Korlátozott
PraNet	~30.5 M	Gyors (~60 FPS)	Jó
HarDNet-MSEG	~33.3 M	Nagyon Gyors (~86 FPS)	Kiváló
Polyp-PVT	~25-30 M (PVT backbone)	Gyors (~66 FPS)	Jó
UltraSeg-108K	0.1 M	Szupergyors (CPU-n is 90 FPS)	Ideális (Mobil/Kapszula)

8. Kutatásmódszertani Ajánlások Szakdolgozathoz

A "milyen modell jobb" kérdés megválaszolása után a következő lépés a kísérlet helyes megtervezése. Ahhoz, hogy a szakdolgozat tudományosan megalapozott legyen, és a DeepLabV3+ összehasonlítás érvényes ("fair") legyen, az alábbi módszertani szempontokat kell figyelembe venni:

8.1 A "Fair" Összehasonlítás Biztosítása

Gyakori hiba, hogy a hallgatók letöltenek egy előre tanított modern modellt (pl. PraNet), és összehasonlítják egy alapbeállításokkal (from scratch) tanított DeepLabV3+-szal. Ez torz eredményt ad.

- **Backbone Egységesítés:** Ha lehetséges, a DeepLabV3+ modellt erős backbone-nal (pl. ResNet-50 vagy ResNet-101) futtassuk, és használjunk "pre-trained" (ImageNet) súlyokat a tanítás kezdetekor (transfer learning), mivel a PraNet és a többi modell is ezt teszi.²⁹
- **Bemeneti Felbontás:** Minden modellt azonos felbontáson (pl. 352x352 vagy 512x512 pixel) kell tanítani és tesztelni. A HarDNet-MSEG például 352x352-re van optimalizálva.³⁰

8.2 Veszteségfüggvények (Loss Functions) Kiválasztása

A DeepLabV3+ eredetileg **Cross-Entropy (CE)** veszteséget használ. A modern polip szegmentáló modellek (PraNet, Polyp-PVT) azonban összetett, úgynevezett **Structure Loss**-t használnak, amely jellemzően a Weighted Binary Cross Entropy (wBCE) és a Weighted IoU (wIoU) veszteségek összege.³⁰

- **Javaslat:** A szakdolgozatban érdemes a DeepLabV3+-t is betanítani a Structure Loss használatával. Így bizonyítható, hogy a teljesítménykülönbség valóban az *architektúrából* fakad, és nem csak abból, hogy a modernebb modellek jobb hibafüggvényt használnak.

8.3 Adathalmazok Felosztása és Augmentáció

A Kvasir-SEG és a CVC-ClinicDB kis adathalmazok (1000, ill. 612 kép). A túltanulás (overfitting) elkerülése érdekében:

- **Adatfelosztás:** Használja a szabványos felosztást (pl. PraNet split: 900 kép tanító, 100 teszt a Kvasir esetében), hogy az eredményei összevethetők legyenek a szakirodalommal.³²
- **Augmentáció:** Alkalmazzon forgatást, tükrözést és skálázást a tanítás során. Különösen a szín-augmentáció (color jittering) fontos a különböző endoszkópok színhőmérsékletének szimulálására.³³

8.4 Metrikák Értelmezése

A dolgozatban ne csak a Dice pontszámot (hasonlóság) közölje.

- **IoU (Intersection over Union):** Szigorúbb metrika, jobban bünteti a hibákat.

- **Hausdorff Distance (HD95):** Ez a metrika a szegmentált maszk határa és a valós maszk határa közötti maximális távolságot méri. Ez a legkritikusabb a sebészi tervezés szempontjából. A DeepLabV3+ itt szokott a legnagyobbat bukni a PraNet-tel szemben.³⁴
- **Látványbeli Elemzés (Qualitative Analysis):** Mutasson be konkrét példákat, ahol a DeepLabV3+ hibázik (pl. "boundary leakage" vagy kis polipok elmulasztása), és ahol az új modell sikeres.

9. Következtetés

Összefoglalva, a szakdolgozati kutatás számára a **DeepLabV3+** kiváltására és összehasonlítására jelenleg három fő irányvonal ajánlott, attól függően, hogy mi a dolgozat fő fókusza:

1. **Fókusz: Maximális Pontosság és Technológiai Újdonság**
 - **Ajánlott Modell: Polyp-PVT vagy PraNet.**
 - **Érv:** Ezek a modellek képviselik a modern (figyelem-alapú és transzformer) architektúrákat, amelyek szignifikánsan jobban kezelik a polipok morfológiai varianciáját és a globális kontextust.
2. **Fókusz: Valós Idejű Klinikai Alkalmazhatóság**
 - **Ajánlott Modell: HardNet-MSEG.**
 - **Érv:** Ez a modell nyújtja a legjobb kompromisszumot a sebesség és a pontosság között, demonstrálva a hatékony (sparse) neurális hálózatok előnyeit.
3. **Fókusz: Erőforrás-korlátos Környezetek (Mobil/Kapszula Endoszkópia)**
 - **Ajánlott Modell: UltraSeg.**
 - **Érv:** A CPU-alapú futtathatóság bemutatása rávilágít a DeepLabV3+ pazarló erőforrás-igényére és a jövőbeli hordozható orvosi eszközök lehetőségeire.

Bármelyik modellt is választja, a DeepLabV3+ mint "baseline" használata kiváló lehetőséget teremt arra, hogy bemutassa az orvosi képfeldolgozás fejlődését az általános célú szegmentációtól a probléma-specifikus, optimalizált megoldások felé.

Works cited

1. Robust Polyp Detection and Diagnosis through Compositional Prompt-Guided Diffusion Models - arXiv, accessed February 17, 2026, <https://arxiv.org/html/2502.17951v2>
2. PraNet: Parallel Reverse Attention Network for Polyp Segmentation, MICCAI 2020 (Oral). Code using Jittor Framework is available. - GitHub, accessed February 17, 2026, <https://github.com/DengPingFan/PraNet>
3. Exploring the Potential of Ensembles of Deep Learning Networks for Image Segmentation - Unipd, accessed February 17, 2026, <https://www.research.unipd.it/retrieve/eca34a61-80cc-430b-880e-271d380be502/information-14-00657.pdf>

4. HarDNet-MSEG: A Simple Encoder-Decoder Polyp Segmentation Neural Network that Achieves over 0.9 Mean Dice and 86 FPS - arXiv, accessed February 17, 2026, <https://arxiv.org/pdf/2101.07172>
5. ESandML/FCBFormer: Official code repository for: FCN ... - GitHub, accessed February 17, 2026, <https://github.com/ESandML/FCBFormer>
6. Enabling Real-Time Colonoscopic Polyp Segmentation on Commodity CPUs via Ultra-Lightweight Architecture - ResearchGate, accessed February 17, 2026, https://www.researchgate.net/publication/400459362_Enabling_Real-Time_Colonoscopic_Polyp_Segmentation_on_Commodity_CPUs_via_Ultra-Lightweight_Architecture
7. [2512.13376] Unlocking Generalization in Polyp Segmentation with DINO Self-Attention "keys" - arXiv, accessed February 17, 2026, <https://arxiv.org/abs/2512.13376>
8. Colorectal Polyp Segmentation Based on Deep Learning Methods: A Systematic Review, accessed February 17, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12470534/>
9. Polyp Classification: NICE - Endoscopy Campus, accessed February 17, 2026, <https://www.endoscopy-campus.com/en/classifications/polyp-classification-nice/>
10. Diagnostic yield of the Japan NBI Expert Team (JNET) classification for endoscopic diagnosis of superficial colorectal neoplasms in a large-scale clinical practice database - PMC, accessed February 17, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC6683640/>
11. Polyp Segmentation Algorithm Based on the Dual Attention and Fusion Mechanism - MDPI, accessed February 17, 2026, <https://www.mdpi.com/2079-9292/14/12/2316>
12. [2508.09189] Hybrid(Transformer+CNN)-based Polyp Segmentation - arXiv, accessed February 17, 2026, <https://arxiv.org/abs/2508.09189>
13. DeepLabV3+: A Powerful Architecture for Semantic Image Segmentation - Medium, accessed February 17, 2026, <https://medium.com/@deepvisionkararhaider/deeplabv3-a-powerful-architecture-for-semantic-image-segmentation-18c67b10d5be>
14. CL-Polyp: Contrastive Learning for Accurate Polyp Segmentation - arXiv, accessed February 17, 2026, <https://arxiv.org/html/2507.07154v2>
15. An improved semantic segmentation algorithm for high-resolution remote sensing images based on DeepLabv3+ - PMC, accessed February 17, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11055951/>
16. Lightweight colon polyp segmentation algorithm based on improved DeepLabV3+, accessed February 17, 2026, <https://www.jcancer.org/v15p0041.htm>
17. Transformers in medical image segmentation: a narrative review - PMC, accessed February 17, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC10722011/>
18. james128333/HarDNet-MSEG - GitHub, accessed February 17, 2026, <https://github.com/james128333/HarDNet-MSEG>
19. [2101.07172] HarDNet-MSEG: A Simple Encoder-Decoder Polyp Segmentation Neural Network that Achieves over 0.9 Mean Dice and 86 FPS - arXiv, accessed February 17, 2026, <https://arxiv.org/abs/2101.07172>

20. Polyp segmentation in colonoscopy images using DeepLabV3++ - ResearchGate, accessed February 17, 2026, https://www.researchgate.net/publication/382654426_Polyp_segmentation_in_colonoscopy_images_using_DeepLabV3
21. [Literature Review] Polyp segmentation in colonoscopy images using DeepLabV3++, accessed February 17, 2026, <https://www.themoonlight.io/en/review/polyp-segmentation-in-colonoscopy-images-using-deeplabv3>
22. taozh2017/Awesome-Polyp-Segmentation - GitHub, accessed February 17, 2026, <https://github.com/taozh2017/Awesome-Polyp-Segmentation>
23. Polyp-PVT: Polyp Segmentation with Pyramid Vision ... - arXiv.org, accessed February 17, 2026, <https://arxiv.org/abs/2108.06932>
24. arXiv:2208.08352v1 [eess.IV] 17 Aug 2022, accessed February 17, 2026, <https://arxiv.org/pdf/2208.08352>
25. [2512.09307] From SAM to DINOv2: Towards Distilling Foundation Models to Lightweight Baselines for Generalized Polyp Segmentation - arXiv.org, accessed February 17, 2026, <https://arxiv.org/abs/2512.09307>
26. DeepNeXt: a lightweight polyp segmentation algorithm based on multi-scale attention, accessed February 17, 2026, <https://qims.amegroups.org/article/view/130935/html>
27. Kvasir-SEG Dataset - Emergent Mind, accessed February 17, 2026, <https://www.emergentmind.com/topics/kvasir-seg>
28. A complete benchmark for polyp detection, segmentation and classification in colonoscopy images - PMC, accessed February 17, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11458519/>
29. Lightweight colon polyp segmentation algorithm based on improved DeepLabV3+ - Journal of Cancer, accessed February 17, 2026, <https://www.jcancer.org/v15p0041.pdf>
30. Ensembles of Convolutional Neural Networks and Transformers for Polyp Segmentation, accessed February 17, 2026, <https://www.mdpi.com/1424-8220/23/10/4688>
31. A Comparison of Segmentation Methods for Semantic OctoMap Generation - MDPI, accessed February 17, 2026, <https://www.mdpi.com/2076-3417/15/13/7285>
32. arxiv.org, accessed February 17, 2026, <https://arxiv.org/html/2401.11734v1>
33. Benchmarking the Robustness of Deep Segmentation Models via Polyp Editing - arXiv, accessed February 17, 2026, <https://arxiv.org/pdf/2410.16732?>
34. Enhancing medical image segmentation via complementary CNN-transformer fusion and boundary perception - Frontiers, accessed February 17, 2026, <https://www.frontiersin.org/journals/computer-science/articles/10.3389/fcomp.2025.1677905/full>