

Széchenyi István Egyetem

Mesterséges intelligencia alapú, valós idejű döntéstámogató szoftver fejlesztése vastagbélpolipok szegmentálására és klasszifikációjára

Tudományos Diákköri Munka

Készítette:

Birkás Levente

Programtervező Informatikus BSc hallgató

III. évfolyam

és

Kazda Adrián Zsolt

Programtervező Informatikus Bsc hallgató

III. évfolyam

Témavezető: Dr. Horváth Zoltán

Egyetemi tanár

Külső konzulens: Dr. Rácz István

Gasztroenterológus

Kivonat

A vastagbél-daganat világszerte az egyik vezető halálok az onkológiai megbetegedések között, ugyanakkor időben észlelve kiváló eséllyel gyógyítható. A szűrés és diagnosztika "gold standard" eljárása a kolonoszkópia, amelynek során a szakorvos felderíti a béltraktus elváltozásait (polipokat), osztályozza azokat, és szükség esetén azonnali beavatkozást, eltávolítást végez. A polipok pontos, nemzetközi orvosi standardok (pl. NICE, JNET) szerinti klasszifikációja azonban jelentős tapasztalatot és magas szintű szakértelmet kíván. Tudományos munkánk célja az endoszkópos orvosi munka mesterséges intelligencia alapú, valós idejű támogatása. A kutatás során egy konvolúciós neurális hálózatokon (CNN) alapuló klasszifikációs modellt fejlesztettünk, amelynek előfeltétele a léziók pontos lokalizációja és körberajzolása. A klasszifikációs modell Resnet50V2 architektúráján alapul, előtanított súlyokkal, mely a saját adatsorral lett tovább tanítva. Bár ez a folyamat manuálisan is elvégezhető, rendszerünkben a szegmentációt dedikáltan egy DeepLabV3+ architektúrájú mélytanuló modell végzi el automatikusan. A kutatási eredmények gyakorlati hasznosítása érdekében egy komplex szoftveres keretrendszert hoztunk létre. A megoldás lehetővé teszi, hogy az endoszkópos toronyból kábeles kapcsolaton keresztül érkező videojelet egy külső hardveren, in situ dolgozzuk fel. A rendszer a vizsgálat során rendkívül alacsony, 1 másodperc alatti késleltetéssel jeleníti meg a szegmentált maszkot és a klasszifikációs eredményt a saját kijelzőjén. Emellett a szoftver automatikusan adatbázisba menti a rögzített eseteket, ezzel alapot biztosítva a modellek jövőbeli finomhangolásához és továbbfejlesztéséhez. A kifejlesztett alkalmazást valós klinikai környezetben, szakorvosok bevonásával teszteltük. Fontos hangsúlyozni, hogy a rendszer által szolgáltatott eredmények kizárólag tájékoztató jellegű, másodlagos véleményként (second reader) funkcionálnak, és nem helyettesítik az orvosi döntéshozatalt.

1. Motiváció

a) A probléma felvetése

A vastagbélrák világszerte az egyik vezető daganatos halálok, ugyanakkor a korai stádiumban felismert elváltozások esetén a betegek túlélési esélyei kiválóak [1]. A megelőzés és a korai diagnózis legfontosabb eszköze a kolonoszkópia, amelynek során a rákmegelőző állapotnak tekinthető vastagbélpolipok nem csupán azonosíthatók, hanem azonnal el is távolíthatók.

Bár a kolonoszkópia a jelenlegi eljárásrend alapja, a vizsgálat hatékonysága nagymértékben függ a vizsgáló orvos tapasztalatától, leterheltségétől és aktuális koncentrációs képességétől [2]. A szakirodalmi adatok, köztük kiterjedt metaanalízisek alapján az Adenoma Miss Rate (AMR), azaz az észrevétlenül maradt adenomák aránya jelentős, átlagosan a 20-26%-ot is elérheti [3]. A fáradtság, a figyelem lankadása, vagy a polipok nehezen észrevehető morfológiája (például lapos, a környező nyálkahártyába simuló, vagy a bélredők mögött megbúvó elváltozások) mind hozzájárulnak ahhoz, hogy kritikus elváltozások rejtve maradjanak [4].

A pusztán vizuális detektáláson túl komoly kihívást jelent a megtalált elváltozások azonnali megítélése is. A modern endoszkópos eljárások megkövetelik, hogy az orvos lehetőleg már a beavatkozás közben, valós időben el tudja dönteni a polip típusát (például, hogy magas kockázatú adenomatosus, vagy alacsony kockázatú hyperplasticus elváltozásról van-e szó). Ez az úgynevezett "optikai biopszia" komoly rutint igényel, és a végleges szövettani eredmények megérkezéséig bizonytalanságot hordozhat magában [5].

A mesterséges intelligencia és a gépi látás fejlődése megteremtette a lehetőséget ezen emberi hibaforrások minimalizálására. Egy olyan valós idejű döntéstámogató szoftverre van szükség, amely a klinikai munkafolyamatot nem hátráltatva, "második szempárként" funkcionál [6]. Ha az orvos az élő videófolyam (live feed) vizsgálata közben egyetlen gombnyomással objektív és azonnali visszajelzést kap egy gyanús szövetrészlet pontos határaitól (szegmentáció) és biológiai besorolásáról (klasszifikáció), az jelentősen csökkentheti a kognitív terhelést és növelheti a beavatkozás biztonságát [7].

b) Kutatási célok

A kutatás elsődleges célja egy olyan valós idejű, mesterséges intelligencia alapú döntéstámogató szoftver fejlesztése, amely képes az endoszkópos vizsgálatok során észlelt polipok automatikus, magas pontosságú szegmentálására és klasszifikációjára [8]. Ezen eszköz megalkotásával a célunk az orvosi diagnosztika pontosságának növelése, a fals negatív esetek minimalizálása, valamint az optikai biopszia folyamatának támogatása.

A folyamatos, képkockánkénti videóelemzés jelentős számítási kapacitást igényel, és a bélmozgások vagy az eszköz mozgása okozta elmosódás miatt esetenként magas hibaarányal működhet. Ennek kiküszöbölésére egy olyan architektúra kialakítását tűztük ki célul, amely az élő videófolyamból a vizsgáló orvos interakciójára (gombnyomásra) rögzít egy képkockát, és a további elemzést ezen hajtja végre [9]. Ezzel a megközelítéssel a célunk az, hogy az irányítás az orvos kezében maradjon, miközben a hardveres erőforrások kihasználása optimális marad.

A szoftveres folyamat részeként alapvető célunk két korszerű, mélytanulós (Deep Learning) modell integrálása a Python-alapú keretrendszerbe:

- **Szegmentációs célkitűzés:** A polipok pontos térbeli kiterjedésének (morfológiai határainak) pixellszintű meghatározására a DeepLabV3+ architektúrát alkalmazzuk, Mobi-

leNetV2 gerinchálózattal. Célunk a modell betanítása és finomhangolása (fine-tuning) úgy, hogy a kinyert szegmentációs maszkok pontosan elkülönítsék az elváltozást a környező egészséges nyálkahártyától.

- **Klasszifikációs célkitűzés:** [A klasszifikációért felelős szerző kiegészíti]
- **Célértékek és elvárások:**
 - **Valós idő (Latency):** Az end-to-end válaszidő (gombnyomástól az eredmény UI-on történő megjelenéséig) 1 másodperc alatt tartása.
 - **Élő videó (FPS):** A háttérben futó videófolyam zökkenőmentes, 25-30 FPS sebességű megjelenítése.
 - **Pontosság:** Szegmentáció esetén 80% feletti IoU (Intersection over Union) és közel 90%-os Dice-score elérése a tesztalmazon. [Klasszifikációs metrika elvárások helye].

c) Saját hozzájárulás (Contributions)

- Folyamatos videóelemzést felváltó, orvosi interakcióra (triggerre) épülő, alacsony számítási igényű pipeline tervezése.
- Valós klinikai adathalmaz (Petz Aladár Kórház) feldolgozása, tisztítása és a modellek finomhangolása.
- Szegmentációs és klasszifikációs modellek együttes, valós idejű futtatását végző, szálkezelte szoftverarchitektúra implementálása.

d) Szakirodalmi áttekintés és Korszerű megoldások (State of the art)

A daganatos megbetegedések,

- A mesterséges intelligencia és a gépi látás (Computer Vision) eddigi alkalmazásai a gasztroenterológiában.
- Konvolúciós neurális hálózatok (CNN) fejlődése az orvosi képfeldolgozásban.
- A valós idejű orvosi döntéstámogató rendszerek jelenlegi helyzete.
- Korszerű megoldások: DeepLab V3+, Resnet50V2, MobileNetV2, KvasirSEG, és a létező, nem platformfüggetlen megoldások.

e) A dolgozat felépítése

- Rövid áttekintés a fejezetek tartalmáról (Módszerek, Eredmények, Túlmutató alkalmazások, Összegzés).

2. Módszerek

a) Definíciók és jelölések

A kutatás és a mélytanulási modellek kiértékelése során az alábbi orvosi, illetve gépi tanulási fogalmakat és metrikákat használjuk.

Orvosi alapfogalmak

- Kolorektális polip: A vastagbél falán kialakuló kisméretű sejtesomó, bizonyos fajtái rákos elváltozáshoz vezethetnek
- Adenoma: Rákmegelőző állapotnak tekinthető elváltozás, idővel rákos szövetté alakulhat, ennek megelőzése érdekében klinikai eltávolítás szokványos.
- Hiperplasztikus polip: Általában ártalmatlan, alacsony kockázatú elváltozás.
- Optikai biopszia: A polip szövettani típusának valós idejű, kizárólag endoszkópos kép alapján történő, fizikai mintavétel nélküli meghatározása.

Gépi tanulási fogalmak

- Konvolúciós Neurális Hálózat (Convolutional Neural Network - CNN): Olyan deep learning hálózatarchitektúra, amely kifejezetten rácsszerű adatok, elsősorban képek feldolgozására terveztek. A CNN-ek képesek a képek térbeli összefüggéseinek elemzésére, konvolúciós rétegek segítségével.
- Szemantikus szegmentáció: A kép minden egyes pixelének osztályozása (esetünkben: háttér vagy polip), így pontosan meghatározva a keresett objektum morfológiai határait.
- DeepLabV3+: Korszerű szegmentációs architektúra, amely Atrous Spatial Pyramid Pooling (ASPP) modult és egy Encoder-Decoder struktúrát használ a több léptékű (multi-scale) kontextuális információk kinyerésére és a határok éles visszaállítására.

felelős szerző kiegészíti

Értékelési metrikák

- Intersection over Union (IoU): A prediktált maszk és a valós (ground truth) maszk metszetének és uniójának aránya. A szegmentáció legfontosabb pontossági mutatója.
- Dice-score (F1-score szegmentációra): Hasonló az IoU-hoz, de a metszetet kétszeres súllyal veszi figyelembe, így jobban bünteti a fals pozitív és fals negatív pixeleket. Képlete: $2 \times |X \cap Y| / (|X| + |Y|)$.

felelős szerző kiegészíti

- Késleltetés (Latency): Az az időtartam, ami a bemeneti adat (képkocka) beérkezésétől a modell predikciójának UI-on történő megjelenéséig eltelik.

b) Adatkészlet & Előfeldolgozás

A modellek tanításához két különböző forrásból származó adathalmazt használtunk fel, hogy biztosítsuk a robusztusságot és az általánosítási képességet:

- **Kvasir-SEG (Nyílt forráskódú):** 1000 darab, gasztrointesztinális polipot tartalmazó kép és a hozzájuk tartozó, szakorvosok által annotált bináris szegmentációs maszk. Ezt a halmazt teljes egészében a tanító (train) adatokhoz adtuk hozzá.
- **SZE / Petz Aladár Kórház (Saját gyűjtés):** 1073 darab polipkép. [Klasszifikációs osztályeloszlás és imbalance kezelése - A klasszifikációért felelős szerző kiegészíti].

Szegmentációs adathalmaz felosztása és előfeldolgozása

- Az adatszivárgás (data leakage) elkerülése érdekében a saját (SZE) adathalmazt szigorúan beteg-azonosító (Patient ID) alapján osztottuk fel. Egy adott betegről készült összes felvétel kizárólag egyetlen halmazba (Train, Val vagy Test) kerülhetett.
- **Train halmaz:** 678 SZE kép + 1000 Kvasir-SEG kép (Összesen: 1678 kép).
- **Validation halmaz:** 189 SZE kép.
- **Test halmaz:** 206 SZE kép.
- **Adat-augmentáció:** A tanító halmaz méretét háromszorosára (3x) növeltük augmentációs technikákkal. Alkalmazott transzformációk: Véletlenszerű skálázás (0.5x - 2.0x), véletlenszerű kivágás (Random Crop, 513x513 pixel), és véletlenszerű vízszintes tükrözés (Horizontal Flip).
- **Normalizáció:** Minden képet tenzorral alakítottunk és az ImageNet adathalmaz átlagával (mean: [0.485, 0.456, 0.406]) és szórásával (std: [0.229, 0.224, 0.225]) normalizáltunk.

c) Tanítás és Architektúra

- **Rendszerarchitektúra (Pipeline):** A Python alapú szoftver felépítése.
 - *Működési elv:* A folyamatos videóelemzés helyett a rendszer egy eseményvezérelt (trigger-alapú) folyamatot valósít meg. Az orvos gombnyomására az OpenCV könyvtár kiemel egyetlen képkockát az élő videóstreamből.
 - *Feldolgozási lánc:* Frame kimentés → DeepLabV3+ szegmentáció → Maszk alapján a polip (ROI) kivágása fekete háttérrel → [Klasszifikáció] → Eredmények aszinkron megjelenítése a CustomTkinter alapú UI-on.
 - *Szálkezelés (Threading):* A videóolvasás, a UI frissítése és a neurális hálózatok inferenciája külön szálakon (thread) fut, így a felület nem fagy le a nehéz számítási műveletek alatt, és az élő videóképfolyamat folyamatos marad.
- **Szegmentációs modul:** A DeepLabV3+ architektúrát alkalmaztuk MobileNetV2 gerinchálózattal (backbone), amely kiváló kompromisszumot nyújt a sebesség és a pontosság között. A kimeneti lépésköz (output stride) 16 volt, a kimeneti osztályok száma pedig 2 (háttér és polip).
- **Klasszifikációs modul:** [A klasszifikációért felelős szerző kiegészíti]
- **Kísérleti beállítások (Hyperparaméterek a szegmentációnál):**
 - Loss függvény: CrossEntropyLoss.
 - Optimalizáló: Adam optimizer, 0.001 kezdeti tanulási rátával (learning rate).
 - Scheduler: ReduceLROnPlateau (factor=0.1, patience=3), amely csökkenti a tanulási rátát, ha a validációs IoU nem javul.
 - Batch size: 4.
 - Early stopping: 7 epoch türelmi idővel (patience), a túltanulás (overfitting) elkerülése érdekében. Maximum 50 epoch volt megadva.

- **Környezetek elkülönítése:** A modellek tanítása nagy számítási kapacitású, dedikált GPU-val (CUDA) rendelkező asztali/felhő környezetben történt. Az inferencia (a valós idejű futtatás) tesztelése egy hordozható célhardveren (pl. Zenbook 14 laptop) futott, szimulálva a kórházi endoszkópos torony melletti in situ felhasználást.

3. Eredmények


a) Saját eredmények (Kvantitatív és Vizuális értékelés)

3.1. A szegmentációs modell teljesítménye

A DeepLabV3+ szegmentációs modell tanítása során a legjobb modellt a validációs adathalmazon elért Intersection over Union (IoU) metrika alapján választottuk ki. A korai leállítást (early stopping) alkalmazásával a betanítás a 38. epochban fejeződött be, mivel a modell már nem mutatott érdemi javulást. A legjobb teljesítményt a 31. epochban mentett modell érte el, amely az alábbi kvantitatív eredményeket produkálta a teljesen független (206 képet tartalmazó) teszhalmazon:

- **Validációs IoU:** 84.94%
- **Teszt IoU:** 82.43%
- **Teszt Dice-score:** 89.91%

A közel 90%-os Dice-score kiemelkedő pontosságot jelent az orvosi képfeldolgozás területén, bizonyítva, hogy a modell robusztusan képes a polipok morfológiai határainak pixell-szintű detektálására. Az 1. ábra bemutatja a tanítási folyamat stabilitását, a Loss és az IoU metrikák alakulását a tanítási és validációs adatokon.



1. ábra: A szegmentációs modell tanítási (kék) és validációs (piros) görbéi (Loss és IoU)

- Vizuális példák: Ground truth vs. Predikció (kimeneti maszkok bemutatása - a polyp_cutouts_black mappa alapján később beszúrandó).

3.2. A klasszifikációs modell teljesítménye

lős szerző dolgozza ki.

3.3. A keretrendszer valós idejű teljesítménye

- **Késleltetés (Latency):** Az end-to-end futásidő (a gombnyomástól a szegmentált maszk és a klasszifikációs eredmény UI-on történő megjelenéséig) stabilan 1 másodperc alatt maradt a teszthardveren.
- **Élő videó (FPS):** A háttérben futó videófolyam feldolgozása a szálkezelésnek köszönhetően zavartalan volt, tartva a 25-30 FPS sebességet.

b) Diszkusszió (Kudarok és kihívások összege bemutatása)

- **A triggerelt módszer előnyei:** A folyamatos videófeldolgozással szemben a gombnyomós módszer drasztikusan csökkentette a hardverigényt. Emellett kiküszöbölte a gyors kameramozgásokból eredő elmosódás (motion blur) okozta fals predikciókat, mivel az orvos csak a stabil, fókuszált képeknél kért elemzést.
- **Szegmentációs kihívások és hibaesetek:**
 - *Fals pozitívok:* A modell esetenként polipként azonosított erős fényvisszaverődéseket (csillogást), vastagabb bélredőket, vagy székletmaradványokat.
 - *Fals negatívok:* A lapos (flat), a nyálkahártyába simuló elváltozások szegmentálása esetenként pontatlan volt, különösen rossz fényviszonyok vagy részleges kitakarás esetén.

előző szerző kiegészíti

4. Túlmutató alkalmazások

- **Klinikai integráció:** A szoftver "második szempárként" (second reader) funkcionálva beilleszthető a mindennapi klinikai gyakorlatba, csökkentve az orvosok kognitív terhelését és az Adenoma Miss Rate-et (AMR).
- **Továbbfejlesztési lehetőségek:** Erősebb hardverkörnyezet (pl. dedikált AI gyorsítók) esetén a rendszer átállítható folyamatos, framenkénti monitorozásra, amely automatikus riasztási (bounding box) funkciókkal hívhatja fel a figyelmet a periférián megjelenő polipokra.

5. Összegzés

a) A probléma és az eredmények összefoglalása

- A vastagbélrák szűrésének fontossága és az erre fejlesztett Python-alapú döntéstámogató eszköz sikeres implementációjának rövid leírása.

b) Főbb elért eredmények, a diszkusszió összegzése

- A DeepLabV3+ és a klasszifikációs modell együttes alkalmazásával elért konkrét pontossági (közel 90% Dice-score) és sebességi (<1s latency) mérőszámok kiemelése.
- A megoldás gyakorlati hasznosíthatóságának megerősítése.

c) További lépések

- Jövőbeli tervek: a modell továbbképzése nagyobb adathalmazon, klinikai tesztelés valós körülmények között, vagy a felhasználói felület ergonómiai fejlesztése.

6. Felhasznált irodalom

- [1] Bray, F., Ferlay, J., Soerjomataram, I., Siegel, R. L., Torre, L. A., & Jemal, A. (2018). Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: a cancer journal for clinicians*, 68(6), 394-424.
- [2] Corley, D. A., Jensen, C. D., Marks, A. R., Zhao, W. K., Lee, J. K., Doubeni, C. A., ... & Levin, T. R. (2014). Adenoma detection rate and risk of colorectal cancer and death. *The New England journal of medicine*, 370(14), 1298-1306.
- [3] Zhao, S., Wang, S., Pan, P., Xia, T., Chang, X., Yang, X., ... & Qiu, M. (2019). Magnitude, risk factors, and factors associated with adenoma miss rate of tandem colonoscopy: a systematic review and meta-analysis. *Gastroenterology*, 156(6), 1661-1674.
- [4] Ahn, S. B., Han, D. S., Bae, J. H., Byun, T. J., Kim, J. P., & Eun, C. S. (2012). The miss rate for colorectal adenoma determined by quality-adjusted, back-to-back colonoscopies. *Gut and liver*, 6(1), 64.
- [5] Mori, Y., Kudo, S. E., Wakamura, K., Misawa, M., Ogawa, Y., Kutsukawa, M., ... & Ishida, F. (2018). Novel video endoscope using an artificial intelligence system for real-time optical biopsy of colorectal polyps: a pilot study. *Gastrointestinal endoscopy*, 88(3), 529-534.
- [6] Repici, A., Badalamenti, M., Maselli, R., Correale, L., Radaelli, F., Rondonotti, E., ... & Hassan, C. (2020). Efficacy of real-time computer-aided detection of colorectal neoplasia in a randomized trial. *Gastroenterology*, 159(2), 512-520.
- [7] Ren, J., et al. (2024). Artificial intelligence algorithms for real-time detection of colorectal polyps during colonoscopy: a review. *American Journal of Cancer Research*, 14(11), 5456-5470.
- [8] Jha, D., Smedsrud, P. H., Riegler, M. A., Halvorsen, P., de Lange, T., Johansen, D., & Johansen, H. D. (2020). Kvasir-seg: A segmented polyp dataset. In *MultiMedia Modeling: 26th International Conference, MMM 2020, Daejeon, South Korea, January 5–8, 2020, Proceedings, Part II 26* (pp. 451-462). Springer International Publishing.
- [9] Ahmad, O. F., Soares, A. S., Mazomenos, E., Brandao, P., Vega, R., Seward, E., ... & Lovat, L. B. (2019). Artificial intelligence and computer-aided diagnosis in colonoscopy: current evidence and future directions. *The Lancet Gastroenterology & Hepatology*, 4(1), 71-80.
- [10] Chen, L. C., Papandreou, G., Kokkinos, I., Murphy, K., & Yuille, A. L. (2017). DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs. *IEEE transactions on pattern analysis and machine intelligence*, 40(4), 834-848.
- [11] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Identity mappings in deep residual networks. In *Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14* (pp. 630-645). Springer International Publishing.
- [12] Vinsard, D. G., Mori, Y., Misawa, M., Kudo, S. E., Rosty, C., Wallace, M. B., ... & Sharma, P. (2019). Quality assurance of computer-aided detection and diagnosis in colonoscopy. *Gastrointestinal endoscopy*, 90(1), 55-63.

- [13] Dekker, E., Tanis, P. J., Vleugels, J. L., Kasi, P. M., & Wallace, M. B. (2019). Colorectal cancer. *The Lancet*, 394(10207), 1467-1480. *(Ez egy kiváló, alapvető áttekintő cikk a vastagbélrákról és a polipokról).*
- [14] Rex, D. K., Ahnen, D. J., Baron, J. A., Batts, K. P., Burke, C. A., Burt, R. W., ... & You, Y. N. (2012). Serrated lesions of the colorectum: review and recommendations from an expert panel. *The American journal of gastroenterology*, 107(9), 1315-1329.
- [15] Ignjatovic, A., East, J. E., Suzuki, N., Vance, M., Guenther, T., & Saunders, B. P. (2009). Optical diagnosis of small colorectal polyps at routine colonoscopy (Detect InSpect ChAracterise Resect and Discard; DISCARD trial): a prospective cohort study. *The Lancet Oncology*, 10(12), 1171-1178. *(Alapvető cikk az optikai biopsziáról).*
- [16] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778). *(Ez maga az eredeti ResNet publikáció, ezt kötelező hivatkoznod, ha ResNet-et használsz!)*
- [17] Jha, D., et al. (2021). Real-time polyp detection, localization and segmentation in colonoscopy using deep learning. *Ieee Access*, 9, 40496-40510.
- [18] Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information processing & management*, 45(4), 427-437. *(Standard hivatkozás a gépi tanulási metrikákra).*