

- Szenszitivitás (Recall): A ténylegesen pozitív elemek közül a modell által helyesen felismertek aránya. Az orvosi diagnosztikában ez az egyik legkritikusabb metrika, mivel a fals negatív esetek (fel nem ismert rákmegelőző állapot) minimalizálása a fő cél.
- F1-score: A precizitás és a szenzitivitás harmonikus közepe. Olyan esetekben (kiegyenlített adathalmazoknál) ad reális képet a modell teljesítményéről, ahol a puszta pontosság (Accuracy) félrevezető lehet. Ilyen az általunk használt adathalmaz is.
- Intersection over Union (IoU): A prediktált maszk és a valós (ground truth) maszk metszetének és uniójának aránya. A szegmentáció legfontosabb pontossági mutatója.
- Dice-score (F1-score szegmentációra): Hasonló az IoU-hoz, de a metszetet kétszeres súllyal veszi figyelembe, így jobban bünteti a fals pozitív és fals negatív pixeleket.
- Késleltetés (Latency): Az az időtartam, ami a bemeneti adat (képkocka) beérkezésétől a modell predikciójának UI-on történő megjelenéséig eltelik.

b) Adatkészlet & Előfeldolgozás

A modellek tanításához két különböző forrásból származó adathalmazt használtunk fel, hogy biztosítsuk a robusztusságot és az általánosítási képességet:

- **Kvasir-SEG (Nyílt forráskódú):** 1000 darab, gasztrointesztinális polipot tartalmazó kép és a hozzájuk tartozó, szakorvosok által annotált bináris szegmentációs maszk. Ezt a halmazt teljes egészében a tanító (train) adatokhoz adtuk hozzá.
- **SZE / Petz Aladár Kórház (Saját gyűjtés):** 1073 polipképet használtunk, amelyeket nagy felbontású NBI (Narrow Band Imaging) endoszkópos felvételekből gyűjtöttünk. Az eredeti címkézés a JNET osztályozási rendszer szerint történt, a végső címkéket többszörösen validált szövettani eredményekhez igazítottuk. A klasszifikációs modell tanításához a JNET kategóriákat bináris célfeladatra egyszerűsítettük: nem neoplasztikus vs. neoplasztikus elváltozás. Erre a viszonylag korlátozott elemszám miatt volt szükség.


A két modell független adatfelosztása és előfeldolgozása

- Az adatszivárgás (data leakage) elkerülése érdekében a saját (SZE) adathalmazt szigorúan beteg-azonosító (Patient ID) alapján osztottuk fel. A két modellt független, eltérő eloszlású adatszeteken képeztük ki és teszteltük:
- **Szegmentációs felosztás:** A 678 SZE tanító kép mellé az 1000 Kvasir-SEG képet is bevontuk, így a teljes Train halmaz 1678 képből állt. A Validation halmaz 189, míg a szegmentációs Test halmaz 206 SZE képből állt.

- **Klasszifikációs felosztás:** Kizárólag az 1073 darab saját SZE képet használtuk fel. A klasszifikációs modell teljesítményének méréséhez egy külön, független 238 képet tartalmazó tesztalmaidzt ($n = 238$) választottunk ki.
- **Adat-augmentáció:** A szegmentációnál a tanító halmaz méretét háromszorosára (3x) növeltük augmentációs technikákkal (véletlenszerű skálázás 0.5x - 2.0x, Random Crop 513×513, Horizontal Flip). A klasszifikációnál oversampling-et alkalmaztunk az osztályarány-eltolódás kompenzálására.
- **Normalizáció és bemeneti méret:** Minden képet tenzorral alakítottunk és az ImageNet adathalmaz átlagával és szórásával normalizáltunk. A szegmentáció 513 × 513-as, míg a klasszifikáció 512 × 512 pixeles felbontással dolgozott, padding nélkül. A paddinges és padding nélküli előfeldolgozás összehasonlításakor érdemi különbséget nem tapasztaltunk, ezért a további kísérletekben a padding nélküli beállítást használtuk.


c) Tanítás és Architektúra

- **Rendszerarchitektúra (Pipeline):** A Python alapú szoftver felépítése.
 - *Működési elv:* A folyamatos videóelemzés helyett a rendszer egy eseményvezérelt (trigger-alapú) folyamatot valósít meg. Az orvos gombnyomására az OpenCV könyvtár kiemel egyetlen képkockát az élő videóstreamből.
 - *Feldolgozási lánc:* A teljes inferencia folyamatot a 1. ábra szemlélteti. A kiemelt képkockán először a DeepLabV3+ hálózat végzi el a szegmentációt, majd a kapott maszk alapján a rendszer kivágja a léziót (bounding box fekete háttérrel), és ezt a vágott képet adja át a ResNet50V2 klasszifikációs hálózatnak. A végeredmény ezután aszinkron módon jelenik meg a CustomTkinter alapú felhasználói felületen.
 - *Szálkezelés (Threading):* A videóolvasás, a UI frissítése és a neurális hálózatok inferenciája külön szálakon (thread) fut, így a felület nem fagy le a nehéz számí-tási műveletek alatt.



1. ábra: A valós idejű döntéstámogató rendszer adatfeldolgozási folyamata (Pipeline). A folyamat a videójelből kiemelt képkockától a végső klasszifikációs eredmény megjelenítéséig tart.

- **Szegmentációs modul:** A DeepLabV3+ architektúrát alkalmaztuk MobileNetV2 gerinchálózattal (backbone). A kimeneti lépésköz (output stride) 16 volt, a kimeneti osztályok száma pedig 2 (háttér és polip). A tanítás során Adam optimizert ($\text{lr}=0.001$) és CrossEntropyLoss-t használtunk 4-es batch size mellett, early stopping-gal. A hálózat belső működésének (feature maps) vizualizációja segít megérteni, hogy a modell mely képi jellemzőkre (pl. élek, textúrák, alakzatok) fókuszál a szegmentáció során (lásd 2. ábra).



2. ábra: A DeepLabV3+ modell belső jellemzőtérképeinek (feature maps) vizualizációja egy polip felismerése során. Jól látható, ahogy a hálózat az alacsony szintű élektől (Backbone low level) a magas szintű, szemantikus információkig (ASPP) haladva alakítja ki a végső maszkot.

- **Klassifikációs modul:** A modell végső beállítását strukturált hiperparaméter kereséssel (keresztvalidációval) választottuk ki. A hiba számítására a Binary Cross Entropy (BCEWithLogitsLoss) függvényt alkalmaztuk. A keresésben a tanulási rátát (10^{-4} , 5×10^{-5} , 10^{-5}), a batch méretet, a backbone taníthatóságát, valamint az osztályarányok kezelését variáltuk. A végső modell beállításai: a backbone (ResNet50V2) teljes finomhangolása engedélyezve, oversampling alkalmazásával az osztályarány-eltolódás mérséklésére. A döntési küszöb optimalizálása az F1-score maximalizálásával történt. A backbone taníthatósága különösen a recall javulásához járult hozzá, ami orvosi kontextusban a fals negatívok minimalizálása miatt fontos.
- **Környezetek elkülönítése:** A modellek tanítása nagy számítási kapacitású, dedikált GPU-val (CUDA) rendelkező asztali/felhő környezetben történt. Az inferencia (a valós idejű futtatás) tesztelése egy hordozható célhardveren (pl. Zenbook 14 laptop) futott, szimulálva a kórházi endoszkópos torony melletti in situ felhasználást.

3. Eredmények


a) Saját eredmények (Kvantitatív és Vizuális értékelés)

3.1. A szegmentációs modell teljesítménye

A DeepLabV3+ szegmentációs modell tanítása során a legjobb modellt a validációs adathalmazon elért Intersection over Union (IoU) metrika alapján választottuk ki. A korai leállítást (early stopping) alkalmazásával a betanítás a 38. epochban fejeződött be. A legjobb teljesítményt a 31. epochban mentett modell érte el, amely az alábbi kvantitatív eredményeket produkálta a teljesen független (206 képet tartalmazó) teszhalmazon:

- **Validációs IoU:** 84.94%
- **Teszt IoU:** 82.43%
- **Teszt Dice-score:** 89.91%

A közel 90%-os Dice-score kiemelkedő pontosságot jelent az orvosi képfeldolgozás területén. Az 1. ábra bemutatja a tanítási folyamat stabilitását.



3. ábra: A szegmentációs modell tanítási (kék) és validációs (piros) görbéi (Loss és IoU)


3.2. A klasszifikációs modell teljesítménye

A ResNet50V2 alapú klasszifikációs modell tanítási folyamatát a 5. ábra mutatja be. A 20 epochos tanítás során megfigyelhető a Loss értékek csökkenése és az Accuracy növekedése mind a tanító, mind a validációs halmazon.

A klasszifikációs modell tesztkészleten mért konfúziós mátrixa a 6. ábrán látható. Az optimális döntési küszöb meghatározásához az F1, a precision és a recall értékek küszöbfüggvényét vizsgáltuk (7. ábra).

A tesztkészleten ($n = 238$) mért fő metrikák:

- **Accuracy:** 88,7%



4. ábra: Szegmentációs eredmények a tesztalmazon. Balra: Eredeti kép, Középen: Ground Truth (kézi annotáció), Jobbra: Modell predikció

5. ábra: A klasszifikációs modell Accuracy (balra) és Loss (jobbra) görbéi a tanítási folyamat során.

6. ábra: A végső CNN modell konfúziós mátrixa a tesztkészleten (küszöb: 0,74). TP = 142, TN = 69, FP = 14, FN = 13.

7. ábra: F1, precision és recall a döntési küszöb függvényében. A maximális F1 (0,9132) a 0,74-es küszöbnél adódott.

- Precision: 91,0%
- Recall (szenzitivitás): 91,6%
- F1-score: 0,9132
- Specifitás: 83,1%

3.3. A keretrendszer valós idejű teljesítménye

- **Késleltetés (Latency):** Az end-to-end futásidő (a gombnyomástól a szegmentált maszk és a klasszifikációs eredmény UI-on történő megjelenéséig) stabilan 1 másodperc alatt maradt a teszthardveren.
- **Élő videó (FPS):** A háttérben futó videófolyam feldolgozása a szálkezelésnek köszönhetően zavartalan volt, tartva a 25-30 FPS sebességet.

b) Diszkusszió (Kudarcok és kihívások őszinte bemutatása)

- **A triggerelt módszer előnyei:** A folyamatos videófeldolgozással szemben a gombnyomásos módszer drasztikusan csökkentette a hardverigényt. Emellett kiküszöbölte a gyors kameramozgásokból eredő elmosódás (motion blur) okozta fals predikciókat.
- **Szegmentációs kihívások és hibaesetek:**
 - *Fals pozitívok:* A modell esetenként polipként azonosított erős fényvisszaverődéseket (csillogást), vastagabb bélredőket, vagy székletmaradványokat.
 - *Fals negatívok:* A lapos (flat), a nyálkahártyába simuló elváltozások szegmentálása esetenként pontatlan volt.
- **Klasszifikációs kihívások:** A backbone taníthatósága ugyan segítette a recall javulását, azonban a hamis predikciók mélyrehatóbb elemzése még nyitott kérdés, amelyeket gyakran a rossz fényviszonyok és a részleges kitakarások is okozhatnak.

4. Túlmutató alkalmazások

- **Klinikai integráció:** A szoftver "második szempárként" (second reader) funkcionálva beilleszthető a mindennapi klinikai gyakorlatba, csökkentve az orvosok kognitív terhelését és az Adenoma Miss Rate-et (AMR). Platformfüggetlen, így nem kötődik specifikus endoszkópos toronyhoz.
- **Továbbfejlesztési lehetőségek:** Erősebb hardverkörnyezet (pl. dedikált AI gyorsítók) esetén a rendszer átállítható folyamatos, framenkénti monitorozásra. Prototípusként történő kórházi implementálása további adatgyűjtést tenne lehetővé.

5. Összegzés

a) A probléma és az eredmények összefoglalása

- A vastagbélrák szűrésének fontossága és az erre fejlesztett Python-alapú döntéstámogató eszköz sikeres implementációjának rövid leírása.

b) Főbb elért eredmények, a diszkusszió összegzése

- A DeepLabV3+ és a ResNet50V2 modell együttes alkalmazásával elért konkrét pontossági (közel 90% Dice-score szegmentációnál, >91% Szenzitivitás és F1-score a klasszifikációnál) és sebességi (<1s latency) mérőszámok kiemelése.
- A megoldás gyakorlati hasznosíthatóságának megerősítése.

c) További lépések

- Többosztályos kiterjesztés: Jobb eredmények elérése érdekében érdemes lehet nagyobb mennyiségű adatot gyűjteni, főleg ha a jövőben szeretnénk visszatérni a teljes JNET skálára, és több osztályt együttesen kezelni a bináris (neoplasztikus vs. nem neoplasztikus) felosztás helyett.
- Jövőbeli tervek: a modell továbbképzése nagyobb adathalmazon, klinikai tesztelés valós körülmények között, vagy a felhasználói felület ergonomiai fejlesztése.

6. Felhasznált irodalom

[1] Bray, F., Ferlay, J., Soerjomataram, I., Siegel, R. L., Torre, L. A., & Jemal, A. (2018). Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: a cancer journal for clinicians*, 68(6), 394-424.

[2] Corley, D. A., Jensen, C. D., Marks, A. R., Zhao, W. K., Lee, J. K., Doubeni, C. A., ... & Levin, T. R. (2014). Adenoma detection rate and risk of colorectal cancer and death. *The New England journal of medicine*, 370(14), 1298-1306.

[3] Zhao, S., Wang, S., Pan, P., Xia, T., Chang, X., Yang, X., ... & Qiu, M. (2019). Magnitude, risk factors, and factors associated with adenoma miss rate of tandem colonoscopy: a systematic review and meta-analysis. *Gastroenterology*, 156(6), 1661-1674.

[4] Ahn, S. B., Han, D. S., Bae, J. H., Byun, T. J., Kim, J. P., & Eun, C. S. (2012). The miss rate for colorectal adenoma determined by quality-adjusted, back-to-back colonoscopies. *Gut and liver*, 6(1), 64.

[5] Mori, Y., Kudo, S. E., Wakamura, K., Misawa, M., Ogawa, Y., Kutsukawa, M., ... & Ishida, F. (2018). Novel video endoscope using an artificial intelligence system for real-time optical biopsy of colorectal polyps: a pilot study. *Gastrointestinal endoscopy*, 88(3), 529-534.

[6] Repici, A., Badalamenti, M., Maselli, R., Correale, L., Radaelli, F., Rondonotti, E., ... & Hassan, C. (2020). Efficacy of real-time computer-aided detection of colorectal neoplasia in a randomized trial. *Gastroenterology*, 159(2), 512-520.

[7] Ren, J., et al. (2024). Artificial intelligence algorithms for real-time detection of colorectal polyps during colonoscopy: a review. *American Journal of Cancer Research*, 14(11), 5456-5470.

[8] Jha, D., Smedsrud, P. H., Riegler, M. A., Halvorsen, P., de Lange, T., Johansen, D., & Johansen, H. D. (2020). Kvasir-seg: A segmented polyp dataset. In *MultiMedia Modeling*:

26th International Conference, MMM 2020, Daejeon, South Korea, January 5–8, 2020, *Proceedings, Part II* 26 (pp. 451-462). Springer International Publishing.

[9] Ahmad, O. F., Soares, A. S., Mazomenos, E., Brandao, P., Vega, R., Seward, E., ... & Lovat, L. B. (2019). Artificial intelligence and computer-aided diagnosis in colonoscopy: current evidence and future directions. *The Lancet Gastroenterology & Hepatology*, 4(1), 71-80.

[10] Chen, L. C., Papandreou, G., Kokkinos, I., Murphy, K., & Yuille, A. L. (2017). DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs. *IEEE transactions on pattern analysis and machine intelligence*, 40(4), 834-848.

[11] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Identity mappings in deep residual networks. In *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV* 14 (pp. 630-645). Springer International Publishing.

[12] Vinsard, D. G., Mori, Y., Misawa, M., Kudo, S. E., Rosty, C., Wallace, M. B., ... & Sharma, P. (2019). Quality assurance of computer-aided detection and diagnosis in colonoscopy. *Gastrointestinal endoscopy*, 90(1), 55-63.

[13] Dekker, E., Tanis, P. J., Vleugels, J. L., Kasi, P. M., & Wallace, M. B. (2019). Colorectal cancer. *The Lancet*, 394(10207), 1467-1480. *(Ez egy kiváló, alapvető áttekintő cikk a vastagbélrákról és a polipokról).*

[14] Rex, D. K., Ahnen, D. J., Baron, J. A., Batts, K. P., Burke, C. A., Burt, R. W., ... & You, Y. N. (2012). Serrated lesions of the colorectum: review and recommendations from an expert panel. *The American journal of gastroenterology*, 107(9), 1315-1329.

[15] Ignjatovic, A., East, J. E., Suzuki, N., Vance, M., Guenther, T., & Saunders, B. P. (2009). Optical diagnosis of small colorectal polyps at routine colonoscopy (Detect InSpect ChAracterise Resect and Discard; DISCARD trial): a prospective cohort study. *The Lancet Oncology*, 10(12), 1171-1178. *(Alapvető cikk az optikai biopsziáról).*

[16] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778). *(Ez maga az eredeti ResNet publikáció, ezt kötelező hivatkoznod, ha ResNet-et használsz!)*

[17] Jha, D., et al. (2021). Real-time polyp detection, localization and segmentation in colonoscopy using deep learning. *Ieee Access*, 9, 40496-40510.

[18] Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information processing & management*, 45(4), 427-437. *(Standard hivatkozás a gépi tanulási metrikákra).*