

Széchenyi István Egyetem

Mesterséges intelligencia alapú, valós idejű döntéstámogató szoftver fejlesztése vastagbélpolipok szegmentálására és klasszifikációjára

Tudományos Diákköri Munka

Készítette:

Birkás Levente

Programtervező Informatikus BSc hallgató

III. évfolyam

és

Kazda Adrián Zsolt

Programtervező Informatikus Bsc hallgató

III. évfolyam

Témavezető: Dr. Horváth Zoltán

Egyetemi tanár

Külső konzulens: Dr. Rácz István

Gastroenterológus

1. Motiváció

a) A probléma felvetése

A vastagbélrák világszerte az egyik vezető daganatos halálok, ugyanakkor a korai stádiumban felismert elváltozások esetén a betegek túlélési esélyei kiválóak [1]. A megelőzés és a korai diagnózis legfontosabb eszköze a kolonoszkópia, amelynek során a rákmegelőző állapotnak tekinthető vastagbélpolipok nem csupán azonosíthatók, hanem azonnal el is távolíthatók.

Bár a kolonoszkópia a jelenlegi eljárásrend alapja, a vizsgálat hatékonysága nagymértékben függ a vizsgáló orvos tapasztalatától, leterheltségétől és aktuális koncentrációs képességétől [2]. A szakirodalmi adatok, köztük kiterjedt metaanalízisek alapján az Adenoma Miss Rate (AMR), azaz az észrevétlenül maradt adenomák aránya jelentős, átlagosan a 20-26%-ot is elérheti [3]. A fáradtság, a figyelem lankadása, vagy a polipok nehezen észrevehető morfológiája (például lapos, a környező nyálkahártyába simuló, vagy a bélredők mögött megbúvó elváltozások) mind hozzájárulnak ahhoz, hogy kritikus elváltozások rejtve maradjanak [4].

A pusztán vizuális detektáláson túl komoly kihívást jelent a megtalált elváltozások azonnali megítélése is. A modern endoszkópos eljárások megkövetelik, hogy az orvos lehetőleg már a beavatkozás közben, valós időben el tudja dönteni a polip típusát (például, hogy magas kockázatú adenomatosus, vagy alacsony kockázatú hyperplasticus elváltozásról van-e szó). Ez az úgynevezett "optikai biopszia" komoly rutint igényel, és a végleges szövettani eredmények megérkezéséig bizonytalanságot hordozhat magában [5].

A mesterséges intelligencia és a gépi látás fejlődése megteremtette a lehetőséget ezen emberi hibaforrások minimalizálására. Egy olyan valós idejű döntéstámogató szoftverre van szükség-

ség, amely a klinikai munkafolyamatot nem hátráltatva, "második szempárként" funkcionál [6]. Ha az orvos az élő videófolyam (live feed) vizsgálata közben egyetlen gombnyomással objektív és azonnali visszajelzést kap egy gyanús szövetrészlet pontos határaitól (szegmentáció) és biológiai besorolásáról (klasszifikáció), az jelentősen csökkentheti a kognitív terhelést és növelheti a beavatkozás biztonságát [7].

b) Kutatási célok

A kutatás elsődleges célja egy olyan valós idejű, mesterséges intelligencia alapú döntéstámogató szoftver fejlesztése, amely képes az endoszkópos vizsgálatok során észlelt polipok automatikus, magas pontosságú szegmentálására és klasszifikációjára [8]. Ezen eszköz megalkotásával a célunk az orvosi diagnosztika pontosságának növelése, a fals negatív esetek minimalizálása, valamint az optikai biopszia folyamatának támogatása.

A folyamatos, képkockánkénti videóelemzés jelentős számítási kapacitást igényel, és a bélmozgások vagy az eszköz mozgatása okozta elmosódás miatt esetenként magas hibaarányal működhet. Ennek kiküszöbölésére egy olyan architektúra kialakítását tűztük ki célul, amely az élő videófolyamból a vizsgáló orvos interakciójára (gombnyomásra) rögzít egy képkockát, és a további elemzést ezen hajtja végre [9]. Ezzel a megközelítéssel a célunk az, hogy az irányítás az orvos kezében maradjon, miközben a hardveres erőforrások kihasználása optimális marad.

A szoftveres folyamat részeként alapvető célunk két korszerű, mélytanulós (Deep Learning) modell integrálása a Python-alapú keretrendszerbe:

- **Szegmentációs célkitűzés:** A polipok pontos térbeli kiterjedésének (morfológiai határainak) pixellszintű meghatározására a DeepLabV2 architektúrát alkalmazzuk [10]. Célunk a modell betanítása és finomhangolása (fine-tuning) úgy, hogy a kinyert szegmentációs maszkok pontosan elkülönítsék az elváltozást a környező egészséges nyálkahártyától.
- **Klasszifikációs célkitűzés:** A szegmentált régió (Region of Interest) biológiai besorolását – azaz az elváltozás típusának (pl. adenoma vs. hyperplasticus) előrejelzését – a ResNet50V2 hálózat implementálásával végezzük [11]. A cél a szövettani eredményekkel magas egyezést mutató predikciós pontosság elérése, és a fals negatívok minimalizálása. Ehhez a szenzitivitás értékét szeretnénk 90% fölött tartani, figyelve az F1-score-ra is (az adatsor kiegyensúlyozatlansága miatt).

Végül technológiai célkitűzésünk a rendszer end-to-end futásidejének minimalizálása. A gombnyomástól a képrögzítésen, a szegmentáláson és a klasszifikáláson át az eredmények grafikus felületen történő megjelenítéséig eltelő időnek kellően alacsonynak kell lennie ahhoz, hogy a szoftver a klinikai gyakorlatban elvárt, azonnali visszacsatolást biztosítsa a vizsgálóorvos számára [12].

c) Szakirodalmi áttekintés

A daganatos megbetegedések,

- A mesterséges intelligencia és a gépi látás (Computer Vision) eddigi alkalmazásai a gasztroenterológiában.
- Konvolúciós neurális hálózatok (CNN) fejlődése az orvosi képfeldolgozásban.
- A valós idejű orvosi döntéstámogató rendszerek jelenlegi helyzete.

d) A dolgozat felépítése

- Rövid áttekintés a fejezetek tartalmáról (Módszerek, Eredmények, Túlmutató alkalmazások, Összegzés).

2. Módszerek

a) Definíciók és jelölések

A kutatás és a mélytanulási modellek kiértékelése során az alábbi orvosi, illetve gépi tanulási fogalmakat és metrikákat használjuk.

Orvosi alapfogalmak

- Kolorektális polip: A vastagbél falán kialakuló kisméretű sejtcsoomó, bizonyos fajtái rákos elváltozáshoz vezethetnek
- Adenoma: Rákmegelőző állapotnak tekinthető elváltozás, idővel rákos szövetté alakulhat, ennek megelőzése érdekében klinikai eltávolítás szokványos.
- Hiperplastikus polip: Általában ártalmatlan, alacsony kockázatú elváltozás.
- Optikai biopszia: A polip szövettani típusának valós idejű, kizárólag endoszkópos kép alapján történő, fizikai mintavétel nélküli meghatározása.

Gépi tanulási fogalmak (klasszifikáció)

- Bináris képklasszifikáció: Olyan felügyelt gépi tanulási feladat, amely során egy x bemeneti képhez, egy y prediktált diszkrét osztálycímét rendelünk ahol $y \in \{0, 1\}$.
- Konvolúciós Neurális Hálózat (Convolutional Neural Network - CNN): Olyan deep learning hálózataarchitektúra, amely kifejezetten rácsszerű adatok, elsősorban képek feldolgozására terveztek. A CNN-ek képesek a képek térbeli összefüggéseinek elemzésére, konvolúciós rétegek segítségével. Ezek a rétegek egy mozgó ablakkal (ún. kernel vagy szűrő) matematikai konvolúciós műveletet végeznek a bemeneti képen. Ezzel a korai rétegek alacsony szintű jellemzőket (textúrák, élek), míg a későbbi rétegek komplexebb alakzatokat (pl. polipok morfológiája) vonnak ki.
- ResNet (Residual Network): Egy mély CNN architektúra, amelyet a nagyon sok rétegű hálózatok betanításakor fellépő "vanishing gradient" probléma megoldására, fejlesztettek ki. [16] A ResNet alapja a reziduális blokk, ami a "skip connection"-t használ. Ennek segítségével a bemeneti információk bizonyos rétegek átugrásával, közvetlenül továbbítódnak a hálózat mélyebb részeibe. Emiatt a ResNet architektúrák nagyon sok réteggel rendelkeznek, megőrizve a pontosságot.

Klasszifikációs értékelési metrikák

A bináris osztályozó modell teljesítményének mérésére konfúziós mátrixot és annak elemeit használjuk fel. előléseink a következők: **TP** (True Positive - Helyesen felismert adenoma), **TN** (True Negative - Helyesen felismert hyperplastikus polip), **FP** (False Positive - Tévesen adenomának prediktált hyperplastikus polip), és **FN** (False Negative - Tévesen hyperplastikusnak ítélt, valójában adenoma).

Ezekből az alábbi mind orvosi, mind gépi tanulási kontextusban standardnak számító metrikák származnak:

- Pontosság (Accuracy): Az összes helyesen osztályozott minta aránya az összes vizsgált mintához viszonyítva.
- Precizitás (Precision): A modell által pozitívnak (adenomának) prediktált elemek közül a valóban pozitívak aránya. Megmutatja, mennyire megbízható a modell pozitív jelzése.
- Szenzitivitás (Recall): A ténylegesen pozitív elemek közül a modell által helyesen felismertek aránya. Az orvosi diagnosztikában ez az egyik legkritikusabb metrika, mivel a fals negatív esetek (fel nem ismert rákmegelőző állapot) minimalizálása a fő cél.
- F1-score: A precizitás és a szenzitivitás harmonikus közepe. Olyan esetekben (kiegyenlített adathalmazoknál) ad reális képet a modell teljesítményéről, ahol a pusztán pontosság (Accuracy) félrevezető lehet. Ilyen az általunk használt adathalmaz is.
- Szegmentációs fogalmak
 - IoU, Dice-score, bounding box, binary maszk
 - szemantikus szegmentáció vs objektum detektálás
- Valós idejű feldolgozás dolgai (fps, inference time, latency)

b) Korszerű megoldások (State of the art)

DeepLab V3+, Resnet50V2, MobileNetV2, KvasirSEG

Létező, nem platformfüggetlen megoldások

c) Célkitűzések a definíciók tükrében (Ez amúgy lehet redundáns)

Ide kell hogy menjen fps, és milyen gyorsan fusson gombnyomástól klasszifikációig.

Milyen pontossága legyen a klasszifikációnak és a szegmentációnak.

d) Saját módszerek

Klasszifikáció

Adatkészlet & Előfeldolgozás

A tanításhoz a Petz Aladár Korhából gyűjtött 1073 polipképet használtunk. Ezek a képek osztály címkéiket mind szövettan alapján kapták. Mi a címkéket két osztályra osztottuk: negatív osztály, veszélytelen/hiperplasztikus, pozitív osztály adenoma, prekarcinoma vagy akár néhány kép rák is volt. A két osztályra történő bontás után enyhe többségben volt a pozitív osztály

Tanítás

- **Rendszerarchitektúra:** A Python alapú szoftver felépítése, a felhasználói felület (UI) és a videófolyam (live feed) kezelése.
- **Adatkészlet:** A tanításhoz és validáláshoz használt (publikus vagy privát) adathalmazok bemutatása, adat-előfeldolgozás (augmentáció).
- **Szegmentációs modul:** A DeepLabV2 betanításának/finomhangolásának (fine-tuning) folyamata.

- **Klasszifikációs modul:** A ResNet50V2 implementációja, a szegmentált ROI (Region of Interest) átadása a klasszifikálónak.
- **Hardverkörnyezet:** A futtatáshoz és az értékeléshez használt hardver bemutatása, amely a valós idejű inferenciát biztosítja.

e) Példák, nyers eredmények

Ábrák: Screenshot a programról

Seg: Ground truth vs output maszk

CNN: val-loss görbe, confusion matrix

3. Eredmények

a) Saját eredmények

Kiértékeljük az előző fejezet ábráit, közöljük a konkrét eredményeket (f1 score, dice, accuracy, latency)

Latency meg egyéb szoftveres dolgok tesztelése youtube videókon

- A szoftver moduljainak együttes teljesítménye (end-to-end metrikák).
- Klasszifikációs eredmények (konfúziós mátrix, szenzitivitás, specificitás).
- Szegmentációs eredmények (Dice score, IoU eloszlás a tesztalmazon).
- Futásidejű teljesítmény: az inferencia átlagos és maximális ideje másodpercben vagy milliszekundumban.

b) Diszkusszió

- Az eredmények értékelése: miben teljesít jól a szoftver, és mik a gyengeségei?
- A gombnyomásos (triggerelt) módszer előnyei a folyamatos videófeldolgozással szemben (pl. kevesebb motion blur, fókuszáltabb képek, kisebb számítási igény).
- Tipikus hibaesetek elemzése (pl. rossz fényviszonyok, kitakart polipok).

4. Túlmutató alkalmazások

- Hogyan illeszthető be ez a szoftver a mindennapi klinikai gyakorlatba?
- Potenciális továbbfejlesztési lehetőségek: folyamatos, framenkénti (gombnyomás nélküli) monitorozás, riasztási funkciók integrálása.
- A moduláris architektúra adaptálása más endoszkópos vizsgálatokra (pl. gyomortükrözés).

5. Összegzés

a) A probléma és az eredmények összefoglalása

- A vastagbélrák szűrésének fontossága és az erre fejlesztett Python-alapú döntéstámogató eszköz sikeres implementációjának rövid leírása.

b) Főbb elért eredmények, a diszkusszió összegzése

- A DeepLabV2 és a ResNet50V2 együttes alkalmazásával elért konkrét pontossági és sebességi mérőszámok kiemelése.
- A megoldás gyakorlati hasznosíthatóságának megerősítése.

c) További lépések

- Jövőbeli tervek: a modell továbbképzése nagyobb adathalmazon, klinikai tesztelés valószínű körülmények között, vagy a felhasználói felület ergonomiai fejlesztése.

6. Felhasznált irodalom

- [1] Bray, F., Ferlay, J., Soerjomataram, I., Siegel, R. L., Torre, L. A., & Jemal, A. (2018). Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: a cancer journal for clinicians*, 68(6), 394-424.
- [2] Corley, D. A., Jensen, C. D., Marks, A. R., Zhao, W. K., Lee, J. K., Doubeni, C. A., ... & Levin, T. R. (2014). Adenoma detection rate and risk of colorectal cancer and death. *The New England journal of medicine*, 370(14), 1298-1306.
- [3] Zhao, S., Wang, S., Pan, P., Xia, T., Chang, X., Yang, X., ... & Qiu, M. (2019). Magnitude, risk factors, and factors associated with adenoma miss rate of tandem colonoscopy: a systematic review and meta-analysis. *Gastroenterology*, 156(6), 1661-1674.
- [4] Ahn, S. B., Han, D. S., Bae, J. H., Byun, T. J., Kim, J. P., & Eun, C. S. (2012). The miss rate for colorectal adenoma determined by quality-adjusted, back-to-back colonoscopies. *Gut and liver*, 6(1), 64.
- [5] Mori, Y., Kudo, S. E., Wakamura, K., Misawa, M., Ogawa, Y., Kutsukawa, M., ... & Ishida, F. (2018). Novel video endoscope using an artificial intelligence system for real-time optical biopsy of colorectal polyps: a pilot study. *Gastrointestinal endoscopy*, 88(3), 529-534.
- [6] Repici, A., Badalamenti, M., Maselli, R., Correale, L., Radaelli, F., Rondonotti, E., ... & Hassan, C. (2020). Efficacy of real-time computer-aided detection of colorectal neoplasia in a randomized trial. *Gastroenterology*, 159(2), 512-520.
- [7] Ren, J., et al. (2024). Artificial intelligence algorithms for real-time detection of colorectal polyps during colonoscopy: a review. *American Journal of Cancer Research*, 14(11), 5456-5470.
- [8] Jha, D., Smedsrud, P. H., Riegler, M. A., Halvorsen, P., de Lange, T., Johansen, D., & Johansen, H. D. (2020). Kvasir-seg: A segmented polyp dataset. In *MultiMedia Modeling: 26th International Conference, MMM 2020, Daejeon, South Korea, January 5–8, 2020, Proceedings, Part II* 26 (pp. 451-462). Springer International Publishing.
- [9] Ahmad, O. F., Soares, A. S., Mazomenos, E., Brandao, P., Vega, R., Seward, E., ... & Lovat, L. B. (2019). Artificial intelligence and computer-aided diagnosis in colonoscopy: current evidence and future directions. *The Lancet Gastroenterology & Hepatology*, 4(1), 71-80.
- [10] Chen, L. C., Papandreou, G., Kokkinos, I., Murphy, K., & Yuille, A. L. (2017). DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully

connected CRFs. *IEEE transactions on pattern analysis and machine intelligence*, 40(4), 834-848.

[11] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Identity mappings in deep residual networks. In *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14* (pp. 630-645). Springer International Publishing.

[12] Vinsard, D. G., Mori, Y., Misawa, M., Kudo, S. E., Rosty, C., Wallace, M. B., ... & Sharma, P. (2019). Quality assurance of computer-aided detection and diagnosis in colonoscopy. *Gastrointestinal endoscopy*, 90(1), 55-63.

[13] Dekker, E., Tanis, P. J., Vleugels, J. L., Kasi, P. M., & Wallace, M. B. (2019). Colorectal cancer. *The Lancet*, 394(10207), 1467-1480. *(Ez egy kiváló, alapvető áttekintő cikk a vastagbélrákról és a polipokról).*

[14] Rex, D. K., Ahnen, D. J., Baron, J. A., Batts, K. P., Burke, C. A., Burt, R. W., ... & You, Y. N. (2012). Serrated lesions of the colorectum: review and recommendations from an expert panel. *The American journal of gastroenterology*, 107(9), 1315-1329.

[15] Ignjatovic, A., East, J. E., Suzuki, N., Vance, M., Guenther, T., & Saunders, B. P. (2009). Optical diagnosis of small colorectal polyps at routine colonoscopy (Detect InSpect ChAracterise Resect and Discard; DISCARD trial): a prospective cohort study. *The Lancet Oncology*, 10(12), 1171-1178. *(Alapvető cikk az optikai biopsziáról).*

[16] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778). *(Ez maga az eredeti ResNet publikáció, ezt kötelező hivatkoznod, ha ResNet-et használsz!)*

[17] Jha, D., et al. (2021). Real-time polyp detection, localization and segmentation in colonoscopy using deep learning. *Ieee Access*, 9, 40496-40510.

[18] Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information processing & management*, 45(4), 427-437. *(Standard hivatkozás a gépi tanulási metrikákra).*